

CHECKLIST DAN PENILAIAN
MATA KULIAH
METODOLOGI DAN PENELITIAN DIBIDANG TI

NASKAH PENULISAN PROPOSAL SKRIPSI

FAKULTAS TEKNOLOGI INFORMASI (FTI)

Tahun Akademik 2025/2026 Genap

*Contoh terlampir di Versi 5.1b_Buku_Pedoman_Proposal dan Skripsi (Update Maret 2022).**pdf**

NAMA : Muhammad Zailani

NPM : 2310010229

PRODI : Teknik Informatika

KELAS : 6B Reguler Pagi Banjarmasin

Mulai Tgl : 7 Mei 2026

Selesai Tgl : 5 Juli 2026

Petunjuk mengisi checklist!

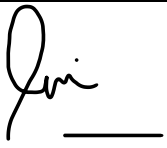
Silakan berikan warna Hijau pada kolom **SESUAI** Jika Anda sudah mengerjakan poin-poin yang ada pada tabel checklist yang telah disusun sesuai panduan dan struktur format penulisan proposal FTI.

Catatan:

1. Selain menggunakan format ini (Checklist dan Template Format Penulisan Proposal), draf proposal tidak akan dinilai.
2. Ketentuan **minimal 8 Laporan/Report** (lihat pada poin 3.7 Rancangan Antarmuka Keluaran Sistem) diwajibkan untuk penelitian yang berfokus pada pengembangan sistem transaksional/administratif, yaitu pada bidang:
   a. **Prodi TI**: *Rekayasa Perangkat Lunak (Software Engineering) & Mobile Computing.*
   b. **Prodi SI**: *Pengembangan Sistem Informasi & E-Government.*
3. Untuk **jumlah laporan/report** dapat menyesuaikan (tidak harus 8) khusus BAB III pada penelitian yang berfokus pada ***perangkat keras, analitik, komputasi matematis, atau tata kelola***, yaitu pada bidang:
   a. **Prodi TI**: Kecerdasan Buatan (AI) & Sains Data, Infrastruktur Jaringan & Keamanan Siber, Sistem Penunjang Keputusan (SPK) & Algoritma Komputasi, serta Internet of Things (IoT) & Pemetaan Spasial (SIG).
   b. **Prodi SI**: Sistem Pendukung Keputusan (SPK), Analitik Data & Data Mining, Tata Kelola & Evaluasi Sistem Informasi, serta Sistem Informasi Geografis (SIG) & Pemetaan Spasial.

NO	PROPOSAL SKRIPSI	STATUS		NILAI
		SESUAI	BELUM SESUAI	
KETENTUAN UMUM				
Kertas HVS berukuran A4 (21 x 29,7 cm) dengan berat **70 gram**. *				
Margin Halaman: batas tepi **kiri 4 cm**, **atas 4 cm**, tepi **kanan 3 cm**, dan **bawah 3 cm.** *				
Judul bab menggunakan ukuran **14 pt**, dicetak tebal (**bold**), HURUF **KAPITAL** SEMUA, tanpa titik, dan diletakkan di tengah.				
Sub bab menggunakan ukuran **12 pt**, dicetak tebal (**bold**), dan huruf kapital hanya pada awal kata saja.				
Tipe huruf *Times New Roman* ukuran **12 pt** untuk **semua teks isi.**				
Jarak antar baris satu dengan baris berikutnya pada teks isi adalah **2 spasi**.				
Jika terdapat *listing program* atau *coding*, menggunakan huruf *Courier New* ukuran 11 pt dengan jarak 1 spasi.				
Penomoran halaman diletakkan di **tengah bawah** untuk **halaman awal** setiap bab dan **pojok kanan atas** untuk **halaman selanjutnya.**				
Keterangan Gambar diletakkan di **tengah bawah gambar**, berjarak **1 spasi.**				
Keterangan Tabel diletakkan di **tengah atas tabel**, berjarak **1 spasi.**				
Jumlah halaman PROPOSAL Minimal 40 (empat puluh) Halaman.				
A. BAGIAN AWAL				
1	**HALAMAN SAMPUL DEPAN (Cover) ***			
2	**HALAMAN DAFTAR ISI ***			
3	**HALAMAN DAFTAR GAMBAR ***			
4	**HALAMAN DAFTAR TABEL ***			
B. BAGIAN INTI				
5	**BAB I PENDAHULUAN**			
6	**1.1 Latar Belakang**			
	1. Uraian Objek Penelitian (Instansi/ Lembaga/ Perusahaan/ Organisasi)			

	a. Bergerak dibidang/ jasa/ pelayanan apa, memiliki cabang/tidak?			
	b. Produk/ jasa/ pelayanan apa saja yang dimiliki?			
	c. Bagaimana Jumlah Karyawan/ pegawai?			
7	2. Uraian Topik penelitian			
8	3. Uraian secara detail apa saja masalah-masalah			
9	4. Uraian penelitian terkait, Jika Anda melanjutkan penelitian dari peneliti sebelumnya			
10	**1.2 Rumusan Masalah**			
11	**1.3 Batasan Masalah**			
12	**1.4 Tujuan Penelitian**			
13	**1.5 Manfaat Penelitian**			
	BAB II TINJAUAN PUSTAKA			
14	**2.1 Landasan Teori**			
15	**2.2 Penelitian Terkait (**minimal 3 Jurnal, dalam bentuk Tabel**)***			
	BAB III METODE PENELITIAN			
16	**3.1 Teknik Pengumpulan Data**			
17	**3.2 Deskripsi Dataset**			
18	**3.3 Pra-pemrosesan Data**			
19	**3.4 Rancangan Model / Arsitektur Algoritma**			
	1. MobileNetV2			
	2. Transfer Learning			
20	**3.5 Rancangan Proses Pelatihan Dan Pengujian Model**			
	a. Training			
	b. Testing			
21	**3.6 Matrik Evaluasi**			
22	**3.7 Rancangan Implementasi Sistem / Prototipe**			
	3.8 Tempat dan Jadwal Penelitian			
B. BAGIAN AKHIR				
23	**DAFTAR PUSTAKA**			
	Banjarmasin,			

Dosen Pengampu Metpen TI	**Mahasiswa**
Nama : Nur Alamsyah, S.Kom., M.Kom	**Nama: Muhammad Zailani**
Tanda Tangan	Tanda Tangan : 

PROPOSAL SKRIPSI

KLASIFIKASI PENYAKIT DAUN PADA BIBIT KELAPA SAWIT MENGGUNAKAN METODE CONVOLUTIONAL NEURAL NETWORK DENGAN ARSITEKTUR MOBILENETV2

Oleh :
MUHAMMAD ZAILANI
NPM: 2310010229



PROGRAM STUDI S1 TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS ISLAM KALIMANTAN
MUHAMMAD ARSYAD AL BANJARI
BANJARMASIN
2026

DAFTAR ISI

Halaman

PROPOSAL SKRIPSI iv

DAFTAR ISI v

DAFTAR GAMBAR vii

DAFTAR TABEL viii

BAB I PENDAHULUAN 9

1.1 Latar Belakang 9

1.2 Rumusan Masalah 13

1.3 Batasan Masalah 14

1.4 Tujuan Penelitian 15

1.5 Manfaat Penelitian 16

BAB II TINJAUAN PUSTAKA 17

2.1 Landasan Teori 17

2.1.1 Computer Vision & Deep Learning 17

2.1.2 Penyakit Daun Kelapa Sawit 19

2.1.3 Convolutional Neural Network (CNN) beserta Rumus Matematis 21

2.1.4 Arsitektur MobileNetV2 & Transfer Learning 23

2.1.5 Augmentasi Data & Hyperparameter Tuning 25

2.1.6 TensorFlow Lite (.tflite) / Mobile 28

2.1.7 Metrik Evaluasi (Confusion Matrix) 30

2.1.8 rumus matematis convolutional neural network 32

2.1.9 arsitektur mobilenetv2 depthwise separable convolution 34

2.1.10 teori transfer learning pada deep learning 36

2.2 Penelitian Terkait 39

BAB III METODE PENELITIAN 45

3.1 Teknik Pengumpulan Data 45

3.2 Deskripsi Dataset 46

3.3 Pra-pemrosesan Data 47
3.4 Rancangan Model / Arsitektur Algoritma 50
3.5 Rancangan Proses Pelatihan dan Pengujian Model 53
3.6 Metrik Evaluasi 55
3.7 Rancangan Implementasi Sistem/Prototipe 58
3.8 Tempat dan Jadwal Penelitian 60
DAFTAR PUSTAKA 62

DAFTAR GAMBAR

Gambar 2. 1 Perbandingan Alur Kerja Machine Learning Konvensional dan Deep Learning pada Computer Vision 18
Gambar 2. 2 Pengelompokan Jenis Penyakit Daun Kelapa Sawit 20
Gambar 2. 3 Arsitektur Blok Bottleneck Residual pada MobileNetV2 24
Gambar 2. 4 Tahapan Proses Transformasi pada Augmentasi Data Citra 27
Gambar 2. 5 Alur Kerja Implementasi Klasifikasi Citra pada Aplikasi Mobile ... 29
Gambar 2. 6 Perbandingan Operasi Konvolusi Standar dan Depthwise Separable Convolution 35
Gambar 2. 7 Tahapan Implementasi Transfer Learning dan Fine-Tuning 38

Gambar 3. 1 Alur Pra-pemrosesan Data 48
Gambar 3. 2 Diagram Arsitektur Model MobileNetV2 dengan Transfer Learning 52
Gambar 3. 3 Alur Proses Pelatihan dan Pengujian Model 55
Gambar 3. 4 Rancangan Mockup Antarmuka Masukan dan Keluaran Prototipe Aplikasi 60

DAFTAR TABEL

Tabel 2. 1 Penelitian Terkait 40

Tabel 3. 1 Rincian Distribusi Kelas pada Dataset Penyakit Daun Kelapa Sawit.. 47

Tabel 3. 2 Kelas Penyakit Kelapa Sawit 56

Tabel 3. 3 Jadwal Kegiatan 61

BAB I
PENDAHULUAN

1.1 Latar Belakang

Kelapa sawit merupakan salah satu komoditas perkebunan strategis yang sangat bergantung pada kualitas kesehatan bibit untuk memastikan hasil panen yang optimal. Dalam praktiknya, pemeliharaan bibit sering kali dihadapkan pada ancaman berbagai penyakit daun yang dapat mengganggu pertumbuhan. Objek utama dalam penelitian ini adalah citra digital penyakit daun kelapa sawit yang bersumber dari dataset publik di platform Kaggle, secara spesifik menggunakan repositori "husamalzain/palm-disease-dataset". Penggunaan dataset publik ini difokuskan untuk menguji algoritma pada data yang memiliki variabilitas tinggi, merepresentasikan kondisi riil di lapangan. Karakteristik citra pada dataset ini mencakup berbagai kondisi visual daun kelapa sawit, mulai dari daun yang sehat hingga yang terinfeksi penyakit dengan tingkat kemiripan gejala yang tinggi, serta memuat variasi kondisi lingkungan, termasuk perbedaan intensitas pencahayaan dan latar belakang citra yang ekstrem.

Topik penelitian ini berfokus pada klasifikasi citra penyakit tanaman menggunakan pendekatan *Computer Vision* dan *Deep Learning*. Secara spesifik, penelitian ini memusatkan perhatian pada penyempurnaan proses deteksi visual otomatis yang mampu membedakan anomali pada daun bibit kelapa sawit secara presisi. Topik ini menjadi esensial karena klasifikasi penyakit secara digital menawarkan solusi diagnosis dini yang lebih konsisten dibandingkan pengamatan manual oleh manusia.

Dalam implementasinya, penelitian ini menggunakan metode *Convolutional Neural Network* (CNN) yang difokuskan pada arsitektur *MobileNetV2*. Pemilihan *MobileNetV2* didasarkan pada kemampuannya dalam menyeimbangkan antara akurasi klasifikasi dan efisiensi komputasi, menjadikannya sangat ideal untuk diintegrasikan pada aplikasi berbasis *mobile* di masa depan. Untuk meningkatkan ketahanan arsitektur ini, diterapkan pendekatan augmentasi data yang ekstrem serta teknik *hyperparameter tuning* spesifik, seperti optimasi *learning rate* dinamis, agar model mampu mengenali pola penyakit dengan akurasi yang lebih tinggi.

Proses identifikasi penyakit daun kelapa sawit secara manual oleh pakar atau praktisi pertanian memerlukan waktu yang lama dan sangat rentan terhadap subjektivitas. Keterbatasan visual manusia dalam membedakan gejala penyakit yang mirip pada tahap awal infeksi sering kali berujung pada diagnosis yang tidak konsisten. Kondisi ini membuat proses pemantauan skala besar di area pembibitan menjadi tidak efisien.

Kurangnya pengetahuan pekerja atau petani mengenai jenis-jenis penyakit spesifik pada bibit kelapa sawit menyebabkan kesalahan penanganan di lapangan. Kesalahan dalam mengidentifikasi pola dan warna daun yang sakit mengakibatkan tindakan pengendalian hama yang tidak tepat sasaran. Hal ini berdampak langsung pada terganggunya pertumbuhan bibit hingga memicu risiko kematian tanaman secara masal.

Penerapan model *deep learning* untuk klasifikasi citra sebelumnya sering kali terhambat oleh kebutuhan sumber daya komputasi yang besar. Penggunaan arsitektur jaringan saraf tiruan yang sangat dalam sering kali menghasilkan ukuran

model yang terlalu berat. Hal ini menjadi masalah krusial karena menyulitkan proses *deployment* model agar dapat berjalan secara luring (*offline*) dan *real-time* pada perangkat *mobile* milik petani di lapangan.

Penelitian terdahulu yang relevan telah dilakukan oleh Ong et al. (2022) yang membahas deteksi penyakit daun kelapa sawit berbasis citra menggunakan CNN. Hasil penelitian tersebut menunjukkan bahwa sistem otomatis mampu mengenali pola visual penyakit secara akurat, namun evaluasi performa modelnya masih terbatas pada lingkungan laboratorium yang relatif terkontrol dan belum diuji secara mendalam terhadap dataset dengan variasi latar belakang ekstrem.

Penelitian oleh Oktafanda (2022) menerapkan CNN untuk klasifikasi citra kualitas bibit dalam upaya meningkatkan produksi kelapa sawit. Meskipun akurasi pengenalan pola citra yang dihasilkan sangat baik, model ini tidak sepenuhnya menyentuh deteksi kesehatan tanaman saat sudah berada di lahan produktif dan masih bergantung pada 612 data citra lokal dari satu lingkungan pembibitan saja.
Yarak et al. (2021) melakukan deteksi pohon dan klasifikasi kesehatan kelapa sawit menggunakan citra satelit resolusi tinggi berbasis *deep learning*. Meskipun pendekatan deteksi spasial skala luas ini sangat efektif untuk memetakan kesehatan perkebunan secara makro dari udara, metode tersebut memiliki keterbatasan fungsional karena tidak mampu mendeteksi jenis penyakit spesifik yang hanya dapat diamati melalui detail tekstur dan bercak pada jarak pandang mikro (dekat daun).

Aji et al. (2013) merancang aplikasi untuk mendeteksi penyakit daun kelapa sawit pada perangkat *mobile* menggunakan ekstraksi fitur pengolahan citra linier

dan klasifikasi *Neural Network* konvensional. Akan tetapi, pendekatan ini masih sangat bergantung pada ekstraksi fitur secara manual (menghitung nilai intensitas warna RGB dan parameter kecerahan satu per satu), sehingga kesulitan membedakan pola penyakit yang sangat kompleks dan hanya mencapai akurasi rata-rata sebesar 87,75%.

Arianda & Hadiwandra (2025) mengimplementasikan arsitektur *MobileNetV2* untuk klasifikasi penyakit daun kelapa sawit yang secara khusus dioptimalkan agar berjalan efisien pada perangkat *mobile*. Meskipun arsitektur yang digunakan sudah ideal dan mencapai akurasi 85%, model ini masih menunjukkan kelemahan dalam mengenali penyakit dengan gejala yang memiliki kemiripan identik, terlihat dari rentannya metrik presisi saat membedakan sampel daun sehat dengan penyakit *Fusarium Wilt*.

Berdasarkan tinjauan penelitian terdahulu, masih terdapat *gap* penelitian yang sangat jelas, khususnya terkait resolusi deteksi visual dan ketahanan model. Keterbatasan yang paling menonjol terletak pada pendekatan deteksi skala makro dari udara, yang terbukti gagal menangkap anomali spesifik pada tekstur mikro permukaan daun secara presisi. Di sisi lain, model yang berfokus pada pengenalan jarak dekat (*close-up*) masih terjebak pada ketidakmampuan mengenali gejala penyakit identik secara konsisten akibat arsitektur jaringan yang belum cukup kebal terhadap distorsi visual, serta masih tingginya dependensi pada ekstraksi fitur manual yang lambat. Hal ini menegaskan adanya urgensi untuk membangun sebuah pemodelan skala mikro yang tidak hanya mampu menyeimbangkan kecepatan

komputasi untuk *mobile*, tetapi juga sangat peka dan presisi dalam membedakan variasi tekstur penyakit pada tingkat daun.

Berdasarkan masalah dan *gap* tersebut, penelitian ini menawarkan solusi berupa klasifikasi kualitas kesehatan bibit kelapa sawit pada level mikro menggunakan metode *Convolutional Neural Network* (CNN) dengan arsitektur *MobileNetV2*. Solusi ini disempurnakan dengan pemanfaatan dataset publik "husamalzain/palm-disease-dataset" dari Kaggle secara masif dan penerapan parameter augmentasi data yang ekstrem. Selain itu, teknik *hyperparameter tuning* spesifik berupa optimasi nilai *learning rate* dinamis akan diterapkan untuk membangun jaringan yang jauh lebih tangguh terhadap kemiripan gejala penyakit. Hasil penelitian ini diharapkan dapat memberikan model klasifikasi spesifik yang sangat akurat, ringan untuk diimplementasikan pada perangkat *mobile*, dan kebal terhadap berbagai distorsi visual di kondisi lapangan yang sesungguhnya.

1.2 Rumusan Masalah

Berdasarkan rincian kendala yang telah dipaparkan pada latar belakang, kondisi permasalahan yang menjadi fokus dalam penelitian ini dapat dirangkum sebagai berikut:

1. Proses identifikasi penyakit daun kelapa sawit secara manual memerlukan waktu yang relatif lama, bersifat subjektif, dan rentan terhadap kesalahan diagnosis pada tahap awal infeksi tanaman akibat keterbatasan visual manusia.

2. Keterbatasan pengetahuan para pekerja atau petani mengenai karakteristik gejala penyakit spesifik pada bibit kelapa sawit memicu tingginya risiko kesalahan penanganan dan keterlambatan pengendalian hama di lapangan.
3. Penerapan model *deep learning* untuk klasifikasi citra sering kali terkendala oleh kebutuhan arsitektur jaringan yang sangat dalam dan ukuran model yang terlalu berat, sehingga menyulitkan proses pemodelan yang efisien untuk dijalankan secara luring (*offline*) pada perangkat *mobile*.
4. Rendahnya tingkat ketahanan model klasifikasi citra tanaman saat ini terhadap distorsi visual berakibat pada tingginya angka salah prediksi (*false positive* dan *false negative*) ketika dihadapkan pada pencahayaan ekstrem, latar belakang citra yang bising, serta beberapa jenis penyakit yang memiliki kemiripan gejala visual sangat identik.

1.3 Batasan Masalah

Agar penelitian ini tetap terarah dan tidak memperluas pembahasan di luar konteks, batasan-batasan masalah dalam penelitian ini ditentukan sebagai berikut:

1. Objek penelitian dibatasi pada citra digital gejala penyakit pada daun bibit kelapa sawit yang bersumber dari dataset publik platform Kaggle dengan nama repositori "husamalzain/palm-disease-dataset".
2. Metode klasifikasi yang digunakan terbatas pada algoritma *Deep Learning* dengan metode *Convolutional Neural Network* (CNN) menggunakan spesifikasi arsitektur *MobileNetV2*.
3. Proses pelatihan model menerapkan strategi *Transfer Learning* dengan memanfaatkan bobot awal (*pretrained weights*) dari dataset ImageNet.

4. Ruang lingkup optimasi model dibatasi pada penerapan parameter augmentasi data serta teknik *hyperparameter tuning* berupa pengaturan nilai tingkat pembelajaran (*learning rate*) secara dinamis.
5. Luaran (*output*) dari penelitian ini terbatas pada berkas model hasil kompilasi akhir yang dikonversi ke dalam format TensorFlow Lite (.tflite) untuk mendukung efisiensi komputasi luring (*offline*) pada perangkat *mobile* Android.
6. Metrik pengujian dan evaluasi performa model dibatasi pada analisis matriks evaluasi yang mencakup tingkat akurasi (*accuracy*), presisi (*precision*), serta nilai kesalahan prediksi berupa *false positive* dan *false negative*.

1.4 Tujuan Penelitian

Tujuan penelitian ini adalah menerapkan algoritma *Convolutional Neural Network* (CNN) dengan arsitektur *MobileNetV2* untuk menghasilkan model klasifikasi penyakit daun bibit kelapa sawit yang mampu beroperasi secara otomatis, cepat, dan objektif guna meminimalisir kesalahan identifikasi oleh pekerja di lapangan. Selain itu, penelitian ini juga bertujuan untuk membangun luaran model klasifikasi yang berukuran ringan dalam format TensorFlow Lite (.tflite) agar dapat diimplementasikan secara luring (*offline*) pada perangkat *mobile*, serta mengevaluasi ketahanan model tersebut melalui penerapan augmentasi data ekstrem dan optimasi *learning rate* dinamis untuk mengukur dan menekan angka kesalahan prediksi (*false positive* maupun *false negative*) saat model dihadapkan pada distorsi visual dan kemiripan gejala penyakit yang identik.

1.5 Manfaat Penelitian

Sesuai dengan rumusan masalah yang telah diuraikan, penyelesaian masalah dalam penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Mempercepat dan meningkatkan objektivitas proses diagnosis penyakit pada daun bibit kelapa sawit di tahap awal infeksi, sehingga ketergantungan pada pengamatan visual manual yang memakan waktu dan rentan kesalahan dapat diminimalisir.
2. Membantu pekerja lapangan atau petani yang kurang berpengalaman dalam mengenali gejala visual penyakit secara spesifik, sehingga tindakan perawatan maupun pengendalian hama dapat dieksekusi lebih cepat dan tepat sasaran untuk mencegah kematian bibit massal.
3. Memberikan kemudahan dan kepraktisan operasional bagi pengguna di area pembibitan melalui ketersediaan model berformat ringan (.tflite) yang dapat langsung dieksekusi secara luring (*offline*) pada perangkat *mobile*, tanpa menuntut spesifikasi perangkat keras yang tinggi.
4. Menghasilkan sistem deteksi dengan tingkat keandalan yang tinggi dalam menekan angka kesalahan prediksi (*false positive* dan *false negative*), sehingga sistem tetap konsisten dan presisi meskipun dihadapkan pada gangguan distorsi visual dari lingkungan nyata, seperti pencahayaan ekstrem atau kemiripan bercak penyakit.

BAB II
TINJAUAN PUSTAKA

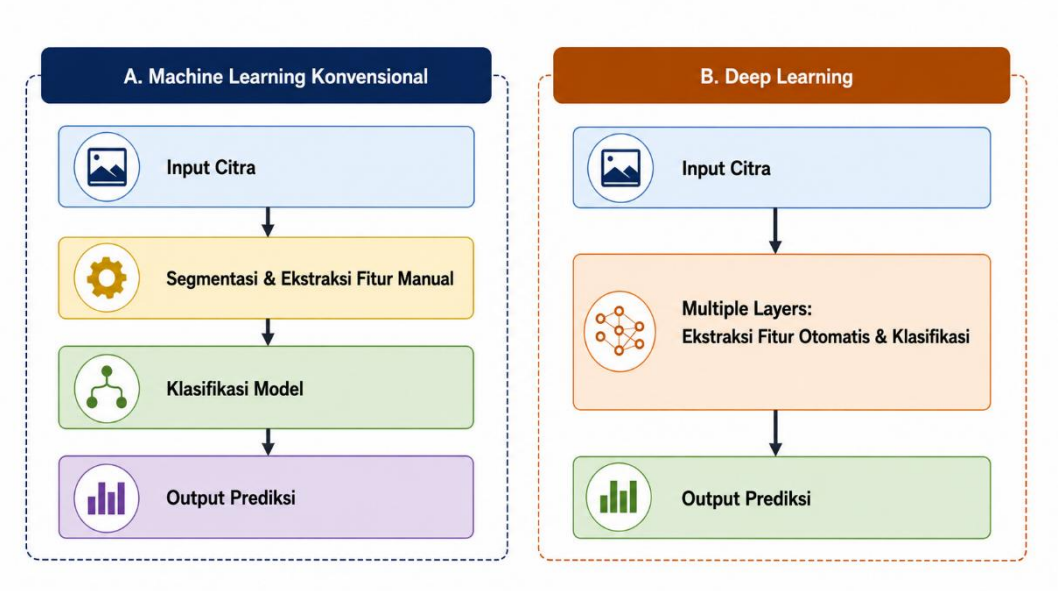
2.1 Landasan Teori

2.1.1 Computer Vision & Deep Learning

Menurut Yarak et al. (2021), deep learning merupakan salah satu prosedur dari machine learning yang memiliki mekanisme kerja menyerupai jaringan otak manusia dan sangat umum diterapkan untuk menganalisis data berupa citra visual. Lebih lanjut, deep learning didefinisikan sebagai cabang dari Kecerdasan Buatan (Artificial Intelligence) yang memegang peran besar dalam pengolahan citra digital karena kemampuannya dalam mempelajari pola secara langsung dari data mentah tanpa memerlukan instruksi komputasi yang eksplisit (Hartono & Muslikh, 2025). Integrasi antara bidang computer vision dan deep learning ini telah menjadi pendekatan mutakhir yang banyak digunakan untuk mengotomatisasi proses identifikasi objek visual, menggantikan metode konvensional yang sebelumnya sangat bergantung pada pemisahan kontur (segmentasi) dan ekstraksi fitur secara manual (Ong et al., 2022).

Karakteristik utama dari deep learning dalam ranah computer vision terletak pada kemampuannya untuk melakukan ekstraksi fitur secara otomatis (Ong et al., 2022). Alih-alih merancang representasi fitur spesifik oleh manusia, model deep learning memproses data visual mentah tersebut melalui kaskade atau serangkaian lapisan jamak (multiple layers) untuk menemukan fitur diskriminatif secara mandiri (Ong et al., 2022). Secara matematis, proses operasional dasar dalam jaringan saraf ini banyak melibatkan transformasi affine, di mana sebuah vektor input dikalikan dengan matriks bobot, kemudian ditambahkan dengan vektor bias, sebelum

akhirnya dilewatkan pada sebuah fungsi aktivasi non-linear untuk menghasilkan suatu representasi output baru (Goodfellow et al., 2016). Perbedaan mendasar antara karakteristik deep learning dengan machine learning konvensional pada computer vision tersebut dapat diilustrasikan pada Gambar 2.1.



Gambar 2. 1 Perbandingan Alur Kerja Machine Learning Konvensional dan Deep Learning pada Computer Vision

Dalam penelitian ini, penerapan konsep computer vision dan deep learning memiliki relevansi yang sangat krusial sebagai fondasi utama untuk memecahkan masalah identifikasi penyakit pada daun bibit kelapa sawit. Pendekatan deep learning terbukti sangat efektif digunakan dalam pengolahan serta klasifikasi citra untuk diagnosis penyakit tanaman, sehingga mampu meminimalisir kelemahan dari pengamatan visual manusia yang lambat dan rentan subjektivitas (Arianda & Hadiwandra, 2025). Selain itu, teknologi computer vision dapat secara cerdas mempelajari pola citra untuk menentukan tingkat kualitas atau kesehatan suatu bibit tanaman (Oktafanda, 2022). Dengan menerapkan deep learning, penelitian ini tidak

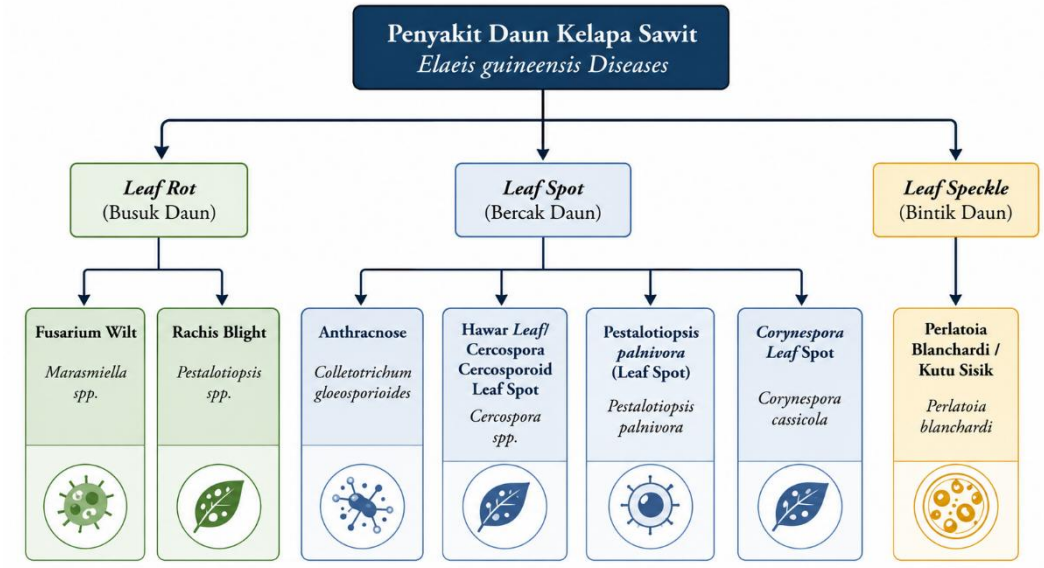
lagi memerlukan proses pengekstraksian fitur warna, bentuk, atau tekstur bercak secara manual yang melelahkan, sehingga model klasifikasi penyakit daun kelapa sawit dapat beroperasi secara lebih cepat, objektif, dan akurat (Ong et al., 2022).

2.1.2 Penyakit Daun Kelapa Sawit

Penyakit daun pada bibit kelapa sawit merupakan kondisi infeksi yang mengganggu pertumbuhan tanaman sejak fase awal, di mana kerusakan pada daun secara signifikan dapat menurunkan efisiensi fotosintesis dan mengurangi hasil panen di masa mendatang (Arianda & Hadiwandra, 2025). Secara umum, penyakit tanaman kelapa sawit dapat dikategorikan menjadi tiga jenis berdasarkan wilayah gejalanya, yaitu penyakit pada bagian akar, batang bawah, dan daun (Ong et al., 2022). Penyakit daun ini umumnya disebabkan oleh serangan patogen jamur parasit yang dapat menyebar secara luas dan cepat di area perkebunan akibat tingginya kelembapan udara lingkungan (Ong et al., 2022). Jika tidak segera diidentifikasi dan ditangani, penyakit daun dapat memicu kerusakan yang masif pada kesehatan bibit, yang pada akhirnya membatasi kualitas serta kuantitas produksi buah kelapa sawit (Aji et al., 2013; Ong et al., 2022).

Karakteristik utama dari penyakit daun kelapa sawit dapat diamati melalui kelainan gejala visual yang muncul pada permukaan daun, batang, maupun biji, seperti terbentuknya bercak-bercak kekuningan atau kecokelatan (Oktafanda, 2022). Berdasarkan jenisnya, manifestasi visual penyakit ini diklasifikasikan ke dalam tiga kelas utama: busuk daun (leaf rot), bercak daun (leaf spot), dan bintik daun (leaf speckle) (Ong et al., 2022). Sebagai contoh, penyakit Anthracnose ditandai dengan bercak terang di bagian tengah atau sisi daun yang meluas menjadi

warna cokelat gelap; penyakit Hawar Leaf (infeksi jamur Curvularia) memunculkan lesi berbentuk elips berwarna cokelat muda dengan pinggiran menguning; sementara infeksi Pestalotiopsis palmarum memunculkan bercak tembus pandang yang berbalut lingkaran oranye atau kekuningan (Aji et al., 2013). Selain itu, terdapat pula variasi penyakit spesifik lainnya seperti Fusarium Wilt (layu fusarium), Rachis Blight (busuk tulang daun), dan kerusakan akibat serangan hama Parlatoria Blanchardi atau kutu sisik (Arianda & Hadiwandra, 2025). Pengelompokan variasi penyakit daun kelapa sawit tersebut dapat diilustrasikan pada Gambar 2.2.



Gambar 2. 2 Pengelompokan Jenis Penyakit Daun Kelapa Sawit

Dalam penelitian ini, pemahaman mendalam mengenai karakteristik visual penyakit daun kelapa sawit memiliki relevansi yang sangat krusial sebagai dasar penentuan kelas (label) klasifikasi pada pemodelan deep learning. Selama ini, pemantauan dan seleksi kesehatan bibit kelapa sawit sering dilakukan secara

manual melalui pengamatan mata telanjang, di mana proses ini memakan waktu yang lama, membutuhkan keahlian patologi khusus, dan rentan terhadap kesalahan penilaian manusia (human error) akibat tingginya kemiripan gejala antar penyakit (Aji et al., 2013; Oktafanda, 2022). Oleh karena itu, dengan mengidentifikasi pola visual penyakit daun secara spesifik, penelitian ini dapat melatih algoritma Convolutional Neural Network (CNN) berarsitektur MobileNetV2 untuk mengotomatisasi proses diagnosis dengan presisi tingkat piksel, sehingga menghasilkan sistem deteksi penyakit bibit kelapa sawit yang jauh lebih cepat, objektif, dan tangguh (Arianda & Hadiwandra, 2025).

2.1.3 Convolutional Neural Network (CNN) beserta Rumus Matematis

Convolutional Neural Network (CNN) didefinisikan sebagai salah satu jenis jaringan saraf tiruan (Neural Network) dalam ranah deep learning yang secara khusus dirancang dan sangat populer digunakan untuk tugas-tugas pemrosesan citra digital serta computer vision (Oktafanda, 2022; Dumoulin & Visin, 2018). Keunggulan utama dari metode CNN terletak pada kemampuannya untuk mempelajari dan mengekstraksi fitur-fitur penting secara otomatis langsung dari data citra mentah melalui serangkaian kaskade berlapis (multiple layers), sehingga mengeliminasi kebutuhan rekayasa fitur (feature handcrafting) secara manual (Ong et al., 2022). Sebagai algoritma klasifikasi citra objek, CNN terbukti memiliki performa komputasi dan tingkat keandalan yang sangat tinggi dalam mengenali serta membedakan satu pola gambar dengan gambar lainnya (Oktafanda, 2022).

Secara arsitektural, algoritma CNN pada dasarnya tersusun atas operasi transformasi affine yang melibatkan dua komponen lapisan utama, yakni lapisan

konvolusi (convolutional layer) dan lapisan pooling (Dumoulin & Visin, 2018). Lapisan konvolusi berfungsi krusial sebagai pengekstraksi fitur citra di mana suatu area matriks input akan dikalikan dengan matriks bobot berupa filter atau kernel, kemudian dijumlahkan dengan skalar bias, sebelum dilewatkan pada sebuah fungsi aktivasi non-linear (seperti fungsi Sigmoid atau ReLU) untuk membentuk representasi feature map baru (Ong et al., 2022; Zhang, 2016). Proses perumusan matematis pada operasi konvolusi dua dimensi ini dapat dinyatakan melalui Persamaan 2.1 (Zhang, 2016). Setelah proses ekstraksi fitur pada tahap konvolusi, feature map tersebut kemudian diteruskan ke lapisan pooling (seperti average pooling atau max pooling) yang berfungsi merangkum sub-area citra guna mereduksi dimensi spasial data tanpa menghilangkan informasi atau fitur diskriminatif yang krusial (Dumoulin & Visin, 2018; Ong et al., 2022).

Dalam penelitian ini, Convolutional Neural Network (CNN) diimplementasikan sebagai metode inti karena karakteristik algoritmanya yang sangat relevan dan tangguh untuk menyelesaikan permasalahan identifikasi penyakit pada daun bibit kelapa sawit. Penggunaan CNN memungkinkan sistem untuk mengklasifikasi citra secara langsung dari pola tekstur, bentuk, dan warna bercak penyakit tanpa harus melalui proses kalkulasi nilai intensitas piksel secara manual yang sangat rentan terhadap kesalahan identifikasi (human error) (Putra et al., 2020; Ong et al., 2022). Dengan arsitektur yang mampu mengekstraksi fitur mikro pada level yang sangat detail, pemodelan CNN yang diterapkan diyakini mampu mendongkrak tingkat akurasi deteksi kesehatan bibit kelapa sawit

meskipun dihadapkan pada kelas penyakit yang memiliki kemiripan gejala visual identik di kondisi lapangan (Oktafanda, 2022; Arianda & Hadiwandra, 2025).

$$C_p(i,j) = \sigma\left(\sum_u \sum_v I\,(i-u, j-v) \cdot k_p(u,v) + b_p\right)$$

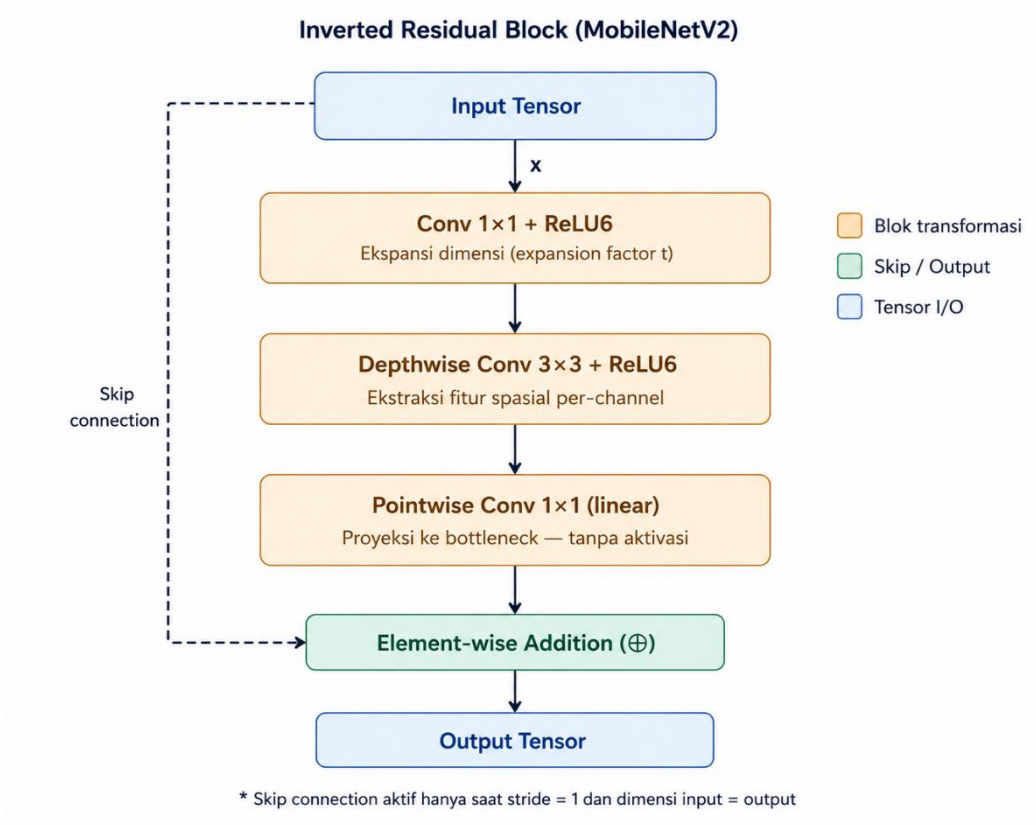
Persamaan 2. 1 rumus/formulasi matematis operasi konvolusi

2.1.4 Arsitektur MobileNetV2 & Transfer Learning

Arsitektur MobileNetV2 didefinisikan sebagai salah satu model jaringan saraf konvolusional (Convolutional Neural Network) mutakhir yang secara khusus dirancang untuk beroperasi secara efisien pada perangkat seluler atau sistem dengan keterbatasan daya komputasi (Sandler et al., 2018). Di sisi lain, transfer learning merupakan teknik pemelajaran mesin yang memanfaatkan pengetahuan (bobot/parameter) dari sebuah model yang telah dilatih sebelumnya pada kumpulan data berskala masif, untuk memecahkan permasalahan baru di domain target (Zhuang et al., 2020). Penggabungan arsitektur MobileNetV2 dengan metode transfer learning ini memungkinkan proses pelatihan model klasifikasi citra menjadi jauh lebih efisien, karena sistem tidak perlu lagi mempelajari ekstraksi fitur visual dasar dari awal, melainkan hanya menyesuaikan parameter yang sudah ada ke tugas spesifik (Ong et al., 2022; Arianda & Hadiwandra, 2025).

Karakteristik utama dari arsitektur MobileNetV2 terletak pada penggunaan struktur Inverted Residual dan Linear Bottleneck yang secara drastis mampu memangkas jumlah parameter serta beban memori komputasi (Sandler et al., 2018). Proses operasi inti pada arsitektur ini sangat bergantung pada Depthwise Separable Convolution, di mana konvolusi standar dipecah menjadi dua tahap efisien:

depthwise convolution yang menyaring input spasial per kanal secara terpisah, dan pointwise convolution (konvolusi 1x1) yang menggabungkan fitur-fitur tersebut menjadi representasi baru (Sandler et al., 2018). Dalam praktiknya menggunakan transfer learning, lapisan ekstraksi fitur dari MobileNetV2 yang telah terlatih pada dataset publik (seperti ImageNet) umumnya akan dibekukan (frozen), sedangkan lapisan klasifikasi bagian ujung (fully connected layer) akan dimodifikasi dan dilatih ulang (fine-tuning) agar relevan dengan jumlah kelas data target (Arianda & Hadiwandra, 2025). Alur pemrosesan pada blok bottleneck residual dalam MobileNetV2 dapat dilihat secara rinci pada Gambar 2.3.



Gambar 2. 3 Arsitektur Blok Bottleneck Residual pada MobileNetV2

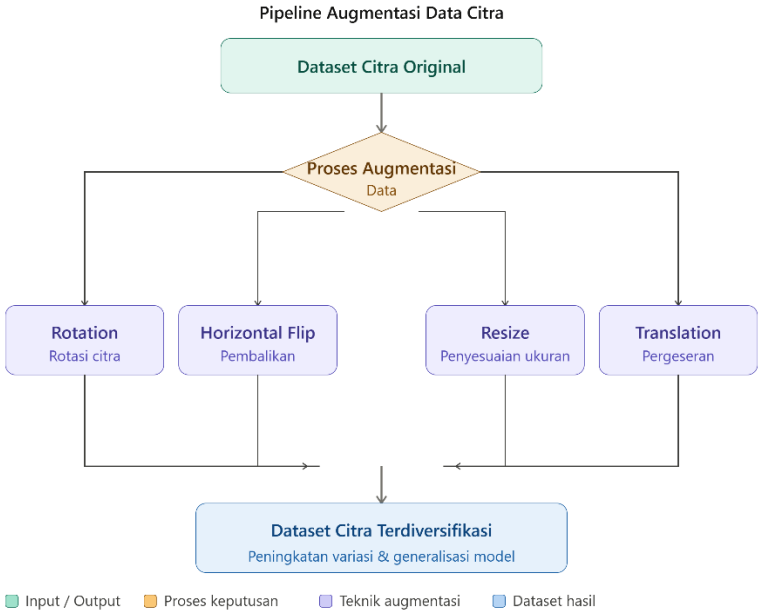
Dalam penelitian ini, penerapan arsitektur MobileNetV2 berbasis transfer learning memiliki relevansi yang sangat krusial untuk mengatasi tantangan keterbatasan komputasi dan data dalam deteksi penyakit daun bibit kelapa sawit. Penggunaan model CNN konvensional seringkali menuntut spesifikasi perangkat keras yang tinggi sehingga sulit diterapkan secara praktis di perkebunan, namun dengan profil arsitektur MobileNetV2 yang ringan, luaran model akan sangat ideal untuk diimplementasikan ke dalam perangkat mobile petani agar dapat berjalan secara luring atau offline (Arianda & Hadiwandra, 2025). Selain itu, dengan jumlah dataset citra penyakit daun yang relatif terbatas, penerapan transfer learning terbukti sangat tangguh untuk mendongkrak performa akurasi sistem, menjaga stabilitas loss, dan menekan durasi training secara signifikan meskipun model dihadapkan pada pola penyakit yang sangat mirip secara visual (Ong et al., 2022; Hartono & Muslikh, 2025).

2.1.5 Augmentasi Data & Hyperparameter Tuning

Augmentasi data didefinisikan sebagai proses memperluas himpunan dataset pelatihan dengan cara memodifikasi data citra yang sudah ada secara artifisial, sehingga keragaman fitur data meningkat dan model pembelajaran mesin dapat lebih mumpuni dalam melakukan generalisasi (Hartono & Muslikh, 2025). Di sisi lain, hyperparameter tuning merupakan proses eksperimen untuk menyesuaikan nilai-nilai parameter konfigurasi eksternal pada model klasifikasi—seperti tingkat pembelajaran (learning rate), iterasi pelatihan (epoch), dan pengoptimal (optimizer)—yang diaplikasikan untuk memperbarui bobot jaringan saraf terhadap gradien kerugian (loss gradient) selama siklus pelatihan berlangsung

(Ong et al., 2022). Penggabungan kedua tahapan ini sangat krusial dalam penerapan algoritma Convolutional Neural Network (CNN) guna mengoptimalkan kapabilitas jaringan dalam mengenali pola dari kumpulan data visual yang terbatas (Oktafanda, 2022).

Secara operasional, karakteristik penerapan augmentasi data mencakup berbagai transformasi spasial dan geometri pada citra asli, seperti penyesuaian dimensi piksel (resize), pembalikan arah horizontal (horizontal flip), rotasi, pemotongan, hingga penyesuaian kecerahan dan pergeseran (translation) (Oktafanda, 2022; Hartono & Muslikh, 2025). Sementara itu, tahapan hyperparameter tuning menitikberatkan pada penemuan kombinasi konfigurasi pelatihan yang paling optimal bagi model; di mana penetapan nilai learning rate yang presisi akan menentukan kecepatan konvergensi generalisasi model, nilai epoch mengatur seberapa sering seluruh data latih dilewatkan dan dipelajari secara berulang oleh jaringan, serta besaran batch size yang membagi jumlah sampel data sebelum disebarkan bertahap ke neural network (Ong et al., 2022; Oktafanda, 2022). Kombinasi beberapa transformasi modifikasi gambar pada tahapan augmentasi data tersebut dapat divisualisasikan pada Gambar 2.4.



Gambar 2. 4 Tahapan Proses Transformasi pada Augmentasi Data Citra

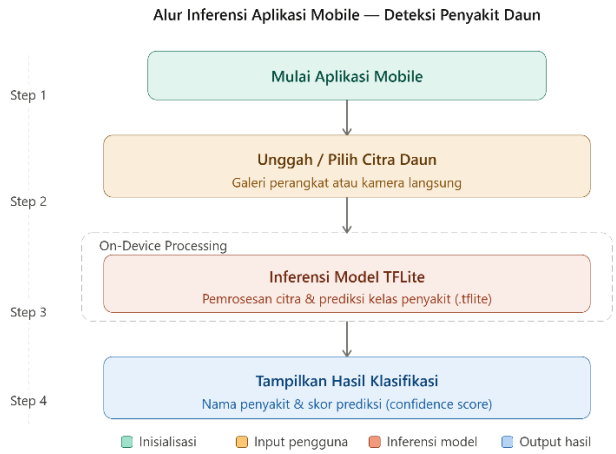
Dalam penelitian ini, penerapan teknik augmentasi data ekstrem dan penyesuaian hyperparameter (tuning) memiliki relevansi yang sangat tinggi untuk mengatasi tantangan kemiripan identik pada gejala visual penyakit daun bibit kelapa sawit di perkebunan. Dengan memperkaya variasi citra melalui augmentasi, arsitektur MobileNetV2 yang dibangun akan menjadi jauh lebih tangguh dalam menghadapi berbagai distorsi visual tak terduga—seperti sudut pencahayaan yang berbeda atau posisi daun yang tidak simetris—sekaligus mencegah terjadinya kegagalan pemodelan akibat overfitting (Hartono & Muslikh, 2025). Selanjutnya, penerapan hyperparameter tuning secara spesifik (khususnya penggunaan optimasi learning rate dinamis dan pengoptimal algoritma seperti Adam) berperan esensial untuk memandu komputasi arsitektur CNN dalam menekan metrik kesalahan prediksi (loss), sehingga akurasi sistem dalam membedakan kelas sampel daun kelapa sawit dapat didongkrak secara lebih objektif dan optimal (Ong et al., 2022).

2.1.6 TensorFlow Lite (.tflite) / Mobile

TensorFlow Lite (.tflite) didefinisikan sebagai format model turunan yang dirancang secara khusus untuk mengintegrasikan dan mengeksekusi algoritma deep learning yang telah dilatih ke dalam platform perangkat bergerak atau mobile (Arianda & Hadiwandra, 2025). Pemanfaatan format ini memungkinkan seluruh proses inferensi—yakni pengenalan pola gambar oleh jaringan saraf tiruan—untuk dapat dijalankan secara langsung pada komputasi lokal perangkat itu sendiri (on-device) tanpa harus memiliki kebergantungan terhadap koneksi jaringan internet (Arianda & Hadiwandra, 2025). Mengingat sifat perangkat mobile yang ringkas dan portabel, pemanfaatan teknologi ini memberikan keuntungan strategis berupa tingkat mobilitas yang tinggi, sehingga implementasi pengolahan citra digital dan deteksi cerdas dapat difungsikan secara luas kapan saja dan di mana saja (Aji et al., 2013).

Secara operasional, tahapan dan karakteristik alur kerja dari aplikasi mobile berbasis model TensorFlow Lite didesain agar sangat praktis dan mudah dioperasikan. Sistem umumnya beroperasi dengan mengizinkan pengguna untuk memilih atau mengunggah citra sampel daun melalui antarmuka aplikasi, di mana citra tersebut kemudian akan dianalisis dan diproses seketika oleh model komputasi yang telah tertanam di dalam memori lokal aplikasi (Arianda & Hadiwandra, 2025). Setelah tahapan inferensi klasifikasi selesai dikalkulasi, aplikasi akan langsung memunculkan luaran atau hasil prediksi kepada pengguna, yang biasanya menampilkan nama kelas penyakit yang berhasil terdeteksi beserta dengan probabilitas atau nilai persentase skor akurasinya (Arianda & Hadiwandra, 2025).

Alur kerja dari implementasi model klasifikasi pada aplikasi mobile tersebut dapat dilihat secara ringkas pada Gambar 2.5.



Gambar 2. 5 Alur Kerja Implementasi Klasifikasi Citra pada Aplikasi Mobile

Dalam penelitian ini, konversi model klasifikasi ke dalam format TensorFlow Lite (.tflite) dan implementasinya pada perangkat mobile memiliki relevansi yang sangat fundamental sebagai bentuk pembuktian konsep (proof-of-concept) bahwa sistem dapat dioperasikan secara nyata di lapangan. Lingkungan perkebunan atau pembibitan kelapa sawit seringkali dihadapkan pada kendala minimnya ketersediaan akses internet serta terbatasnya kehadiran pakar patologi penyakit tanaman secara langsung (Arianda & Hadiwandra, 2025; Aji et al., 2013). Dengan mengintegrasikan arsitektur MobileNetV2 yang ringan ke dalam aplikasi mobile secara luring (offline), hasil dari penelitian ini dapat ditransformasikan menjadi sebuah alat bantu diagnosis penyakit daun yang efisien, praktis, dan dapat langsung berada dalam genggaman para petani guna mendukung langkah pengambilan keputusan secara cepat (Arianda & Hadiwandra, 2025).

2.1.7 Metrik Evaluasi (Confusion Matrix)

Metrik evaluasi dalam sistem pengklasifikasian citra digital merupakan metode pengukuran standar yang digunakan untuk menganalisis secara objektif sejauh mana kinerja dan tingkat keberhasilan suatu model pembelajaran mesin dalam mengenali kelas target (Arianda & Hadiwandra, 2025). Secara khusus, pengukuran performa ini umumnya dihitung berdasarkan confusion matrix, yakni sebuah tabel representasi yang secara sistematis memetakan distribusi hasil prediksi dari model dan membandingkannya dengan label kelas aktual yang sebenarnya (Yarak et al., 2021). Pemanfaatan matriks ini memungkinkan para peneliti untuk memperoleh pemahaman yang lebih komprehensif mengenai pola prediksi, sehingga tidak hanya berfokus pada hasil yang benar secara keseluruhan, melainkan juga mempermudah proses identifikasi terhadap kelas-kelas data yang masih sering mengalami kesalahan klasifikasi (Hartono & Muslikh, 2025).

Secara operasional, karakteristik evaluasi berbasis confusion matrix dibentuk oleh empat komponen nilai dasar, yaitu True Positive (TP) yang merupakan data positif yang berhasil diprediksi benar, True Negative (TN) untuk data negatif yang diprediksi dengan benar, False Positive (FP) di mana model salah memprediksi data negatif sebagai positif, dan False Negative (FN) yang menunjukkan kegagalan model karena memprediksi data positif sebagai negatif (Arianda & Hadiwandra, 2025; Yarak et al., 2021). Keempat elemen dasar tersebut kemudian dikalkulasikan secara matematis untuk menghasilkan ragam metrik evaluasi lanjutan (Ong et al., 2022). Sebagai contoh, accuracy digunakan untuk mengukur proporsi keseluruhan prediksi yang benar, precision meninjau rasio

ketepatan tebakan positif model terhadap seluruh tebakan positifnya, recall mengukur tingkat kepekaan model dalam menemukan seluruh sampel positif yang ada, sedangkan F1-score merupakan nilai harmonisasi yang mencerminkan keseimbangan performa antara precision dan recall (Arianda & Hadiwandra, 2025; Yarak et al., 2021). Formulasi matematis dari perhitungan metrik evaluasi tersebut dapat dilihat pada Persamaan 2.2 hingga Persamaan 2.5.

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

Persamaan 2. 2 Accuracy

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Persamaan 2. 3 Precision

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Persamaan 2. 4 Recall

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Persamaan 2. 5 F1-Score

Dalam penelitian ini, penerapan metrik evaluasi komprehensif berbasis confusion matrix memiliki relevansi yang sangat krusial untuk menguji ketangguhan arsitektur MobileNetV2 dalam mendiagnosis penyakit daun bibit kelapa sawit. Objek penelitian ini melibatkan variasi kelas penyakit dengan kemiripan gejala visual yang sangat identik di lapangan, sehingga evaluasi yang hanya bergantung pada nilai akurasi semata berisiko memberikan kesimpulan yang bias (Arianda & Hadiwandra, 2025). Dengan menganalisis metrik precision, recall, dan F1-score, penelitian ini dapat melacak performa arsitektur deep learning secara

lebih mendalam untuk mendeteksi apakah sistem sudah seimbang dalam mengenali seluruh variasi penyakit kelapa sawit, mampu menekan angka kesalahan diagnosis seperti salah mengenali bercak sehat sebagai penyakit (false positive), serta membuktikan kelayakan implementasi model ini pada aplikasi mobile petani (Hartono & Muslikh, 2025; Ong et al., 2022).

2.1.8 rumus matematis convolutional neural network

Rumusan matematis pada Convolutional Neural Network (CNN) mendefinisikan secara pasti bagaimana transformasi data piksel mentah dilakukan dari satu lapisan ke lapisan berikutnya melalui operasi matriks dasar dan fungsi aktivasi. Secara fundamental, proses komputasi pada CNN melibatkan operasi transformasi affine yang memetakan area input matriks untuk dikalikan secara spasial dengan filter atau matriks bobot (kernel), kemudian ditambahkan dengan besaran vektor bias, dan akhirnya diterapkan pada fungsi aktivasi non-linear untuk memetakan representasi fitur baru (Dumoulin & Visin, 2018; Zhang). Pemodelan matematis ini merupakan inti dari mekanisme abstraksi data pada jaringan saraf tiruan, yang menjamin proses ekstraksi fitur otomatis dapat dihitung secara terukur dan matematis dari setiap iterasi pembelajaran mesin.

Karakteristik tahapan operasional komputasi matematis pada CNN secara umum dihitung secara berlapis yang melibatkan konvolusi spasial, reduksi dimensi, dan perataan vektor. Pada lapisan konvolusi (convolutional layer), nilai piksel pada peta fitur (feature map) baru diperoleh dengan menggeser kernel melintasi citra input, melakukan operasi jumlah perkalian elemen, dan meneruskannya pada fungsi aktivasi seperti Sigmoid (Zhang). Setelah ekstraksi fitur terbentuk, proses

dilanjutkan ke lapisan pooling (seperti average pooling) yang bertugas mereduksi dimensi spasial data dengan merata-ratakan nilai dari area sub-matriks tanpa menghilangkan struktur informasi penting (Zhang). Setelah melalui serangkaian lapisan konvolusi dan pooling, matriks multi-dimensi diratakan (vectorization) menjadi vektor satu dimensi untuk diteruskan pada jaringan terhubung penuh (fully connected layer) yang mengkalkulasi probabilitas klasifikasi akhir (Zhang). Formulasi komputasi matematis dasar untuk operasi lapisan konvolusi dan operasi reduksi dimensi (pooling) tersebut dapat dirincikan pada Persamaan 2.6 dan Persamaan 2.7.

$$C_p^1(i,j) = \sigma\left(\sum_{u=-2}^{2}\sum_{v=-2}^{2} I\,(i-u, j-v)\cdot k_{1,p}^1(u,v) + b_p^1\right)$$

Persamaan 2. 6 Lapisan Konvolusi

$$S_p^1(i,j) = \frac{1}{4}\sum_{u=0}^{1}\sum_{v=0}^{1} C_p^1\,(2i-u, 2j-v)$$

Persamaan 2. 7 Lapisan Average Pooling

Dalam penelitian ini, pemaparan rumus matematis CNN memiliki relevansi yang sangat kuat untuk menguraikan secara ilmiah bagaimana arsitektur pemodelan (seperti MobileNetV2) mengenali citra daun bibit kelapa sawit dari susunan matriks piksel mentah. Dengan menjabarkan formulasi dasar dari operasi konvolusi dan abstraksi dimensi (pooling), mekanisme pengenalan bercak penyakit tidak sekadar dipandang sebagai "kotak hitam" (black box), melainkan sebagai proses komputasi matematika terstruktur yang transparan (Dumoulin & Visin, 2018; Zhang). Hal ini menjadi pondasi teoritis yang valid untuk membuktikan mengapa algoritma CNN

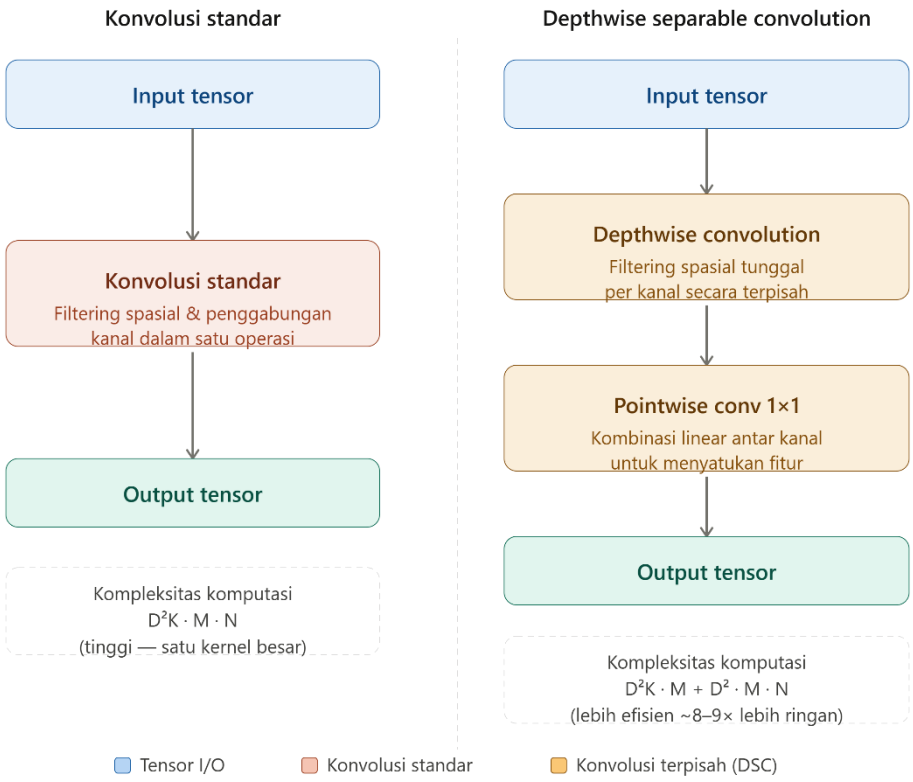
sangat adaptif dalam mengenali gradasi warna dan bentuk lesi dari penyakit daun kelapa sawit, sehingga model mampu menghasilkan diagnosis probabilitas kelas secara objektif dan presisi pada perangkat aplikasi.

2.1.9 arsitektur mobilenetv2 depthwise separable convolution

Arsitektur MobileNetV2 merupakan pemodelan jaringan saraf tiruan konvolusional (Convolutional Neural Network) mutakhir yang secara khusus dirancang untuk menghadirkan efisiensi komputasi tingkat tinggi, sehingga sangat ideal untuk diterapkan pada perangkat dengan keterbatasan sumber daya seperti smartphone atau sistem edge computing (Hartono & Muslikh, 2025). Fondasi utama yang membangun ringannya arsitektur ini bertumpu pada teknik Depthwise Separable Convolution, yang didefinisikan sebagai metode faktorisasi operasi konvolusi standar dengan cara memecahnya menjadi dua lapisan penyaringan yang terpisah (Sandler et al., 2018). Melalui inovasi arsitektur ini, MobileNetV2 mampu mereduksi jumlah parameter dan memori yang berlebihan dalam mengekstraksi fitur visual dari selembar citra, tanpa harus mengorbankan tingkat akurasi prediksi secara drastis (Arianda & Hadiwandra, 2025; Sandler et al., 2018).

Karakteristik utama dari Depthwise Separable Convolution pada model ini terletak pada pemisahan proses konvolusi menjadi tahap depthwise convolution dan pointwise convolution (Sandler et al., 2018). Pada tahap awal, depthwise convolution bertugas menerapkan satu filter spasial tunggal pada setiap kanal input secara independen untuk menangkap fitur-fitur dasar citra (Sandler et al., 2018). Selanjutnya, tahap pointwise convolution (berupa konvolusi berukuran 1x1) difungsikan untuk menggabungkan hasil ekstraksi dari tahap pertama ke dalam

representasi fitur baru melalui kombinasi linear (Sandler et al., 2018). Pemisahan operasi ini secara signifikan memangkas beban komputasi; di mana konvolusi standar konvensional membutuhkan biaya komputasi eksponensial berdasarkan jumlah filter dan kanal, Depthwise Separable Convolution mampu menekannya hingga 8 sampai 9 kali lebih kecil (Sandler et al., 2018). Perbandingan mekanisme dasar antara konvolusi standar dan konvolusi terpisah tersebut dapat diilustrasikan secara konseptual pada Gambar 2.6, sedangkan formulasi komputasinya dapat dirujuk pada Persamaan 2.8.



Gambar 2. 6 Perbandingan Operasi Konvolusi Standar dan Depthwise Separable Convolution

$$\text{Cost}_{\text{separable}} = h_i \cdot w_i \cdot d_i\left(k^2 + d_j\right)$$

Persamaan 2. 8 Biaya Komputasi Depthwise Separable Convolution

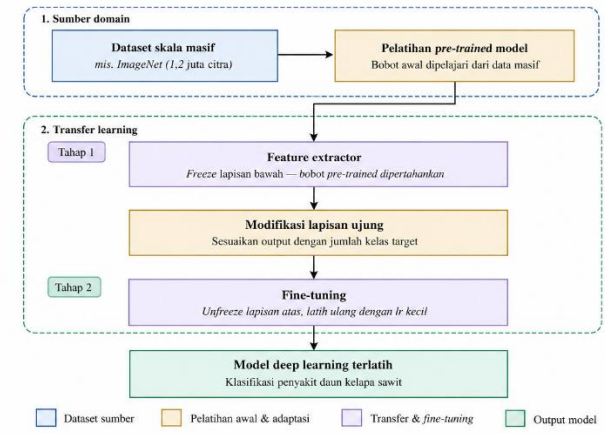
Dalam penelitian ini, pendalaman terhadap konsep Depthwise Separable Convolution pada MobileNetV2 memiliki relevansi yang sangat krusial untuk membuktikan secara teknis mengapa model yang diusulkan sangat ringan dan layak beroperasi pada aplikasi ponsel petani. Pemodelan klasifikasi penyakit daun kelapa sawit umumnya dihadapkan pada kerumitan pola visual dari kelas Fusarium Wilt, Rachis Blight, maupun Parlatoria Blanchardi yang membutuhkan ekstraksi fitur detail (Arianda & Hadiwandra, 2025). Dengan memanfaatkan pemecahan operasi spasial independen per kanal (depthwise) dan penyatuan linear (pointwise), model jaringan saraf dalam penelitian ini mampu membedakan gradasi penyakit daun secara cermat sekaligus meminimalkan durasi training dan beban memori inferensi (Hartono & Muslikh, 2025). Hal ini menjadi justifikasi ilmiah yang kuat dalam membangun alat bantu diagnosis penyakit kelapa sawit luring (offline) berformat .tflite yang andal, cepat, dan hemat sumber daya (Arianda & Hadiwandra, 2025).

2.1.10 teori transfer learning pada deep learning

Transfer learning didefinisikan sebagai suatu teknik atau metode dalam ranah pemelajaran mesin (machine learning) yang memanfaatkan kembali pengetahuan—berupa bobot dan representasi parameter—dari sebuah model yang telah dilatih sebelumnya pada kumpulan data berskala masif, untuk kemudian diaplikasikan guna memecahkan permasalahan baru di domain target yang serupa (Amirah, 2022; Hartono & Muslikh, 2025). Secara konseptual, pendekatan ini berupaya mengekstraksi dan mendaur ulang pengetahuan tersembunyi dari suatu domain sumber (source domain) guna mendongkrak performa fungsi prediksi pada domain target (target domain) (Zhuang et al., 2020). Pemanfaatan transfer learning

sangat dominan dan populer digunakan pada pemodelan deep learning (seperti Convolutional Neural Network) karena mengizinkan model klasifikasi baru untuk mencapai tingkat konvergensi serta akurasi domain yang tinggi, meskipun hanya difasilitasi dengan jumlah sampel data pelatihan yang relatif sedikit atau terbatas (Ong et al., 2022).

Karakteristik tahapan operasional dari transfer learning umumnya diimplementasikan secara berurutan melalui dua pendekatan utama, yakni pemanfaatan model sebagai pengekstraksi fitur (feature extractor) dan penyesuaian bobot lebih dalam atau fine-tuning (Amirah, 2022; Arianda & Hadiwandra, 2025). Pada tahapan ekstraksi fitur, blok lapisan konvolusi awal dari model pra-terlatih (pre-trained model) akan dibekukan atau dikunci (frozen), sementara lapisan ujung dari jaringan klasifikasi akan dibuang lalu digantikan dengan lapisan fully connected layer baru yang disesuaikan secara khusus dengan besaran jumlah kelas data target (Hartono & Muslikh, 2025). Setelah tahapan tersebut terlampaui, pemodelan dapat ditingkatkan melalui tahapan fine-tuning, di mana sebagian lapisan atas dari model dasar diaktifkan kembali (unfrozen) untuk dilatih ulang secara bersama-sama menggunakan tingkat pembelajaran (learning rate) yang sangat rendah (Amirah, 2022; Arianda & Hadiwandra, 2025). Mekanisme pembekuan dan pelatihan ulang selektif ini menjamin agar fitur-fitur visual fundamental (seperti garis atau sudut) yang sudah dikuasai oleh model asal tidak rusak, sekaligus membimbing model untuk mengenali karakteristik spesifik dari data target yang baru (Zhuang et al., 2020). Skema tahapan alur kerja tersebut dapat divisualisasikan secara konseptual pada Gambar 2.7.



Gambar 2. 7 Tahapan Implementasi Transfer Learning dan Fine-Tuning

Dalam penelitian ini, penerapan konsep transfer learning memiliki relevansi yang sangat fundamental untuk menjembatani kelemahan akibat keterbatasan jumlah dataset citra penyakit daun bibit kelapa sawit yang digunakan dalam proses pelatihan (training). Melatih arsitektur deep learning kompleks sejak awal (from scratch) tanpa pengetahuan sebelumnya menuntut beban memori komputasi yang masif dan sangat rentan berujung pada kegagalan generalisasi atau overfitting (Hartono & Muslikh, 2025). Oleh karena itu, dengan mengintegrasikan bobot pra-terlatih publik (seperti ImageNet) ke dalam arsitektur dasar MobileNetV2 melalui fase feature extraction dan fine-tuning, model secara otomasi sudah dibekali "kecerdasan" fundamental yang sangat matang untuk membedakan gradasi warna dan kontur lesi citra secara langsung (Arianda & Hadiwandra, 2025). Implementasi tahapan ini telah terbukti krusial untuk menghasilkan pemodelan pendeteksi penyakit kelapa sawit yang sangat presisi dalam menangkap variasi kemiripan gejala daun, memangkas durasi eksperimen komputasi, serta memastikan model

yang dihasilkan tetap ringan untuk dikonversi menjadi alat diagnosis pada aplikasi seluler luring milik petani (Ong et al., 2022; Arianda & Hadiwandra, 2025).

2.2 Penelitian Terkait

Penelitian-penelitian terdahulu di bidang Kecerdasan Buatan (AI) dan Sains Data telah dilakukan dengan beragam metode dan objek, khususnya dalam lingkup deteksi serta pengklasifikasian penyakit tanaman. Rangkuman lima penelitian yang relevan dengan topik klasifikasi penyakit daun pada bibit kelapa sawit disajikan pada Tabel 2.1. Tabel tersebut memuat judul, nama peneliti dan tahun, permasalahan, metode/algoritma yang digunakan, dan ketidaksesuaian yang menjadi dasar pengembangan penelitian ini. Secara garis besar, metode yang dominan digunakan pada penelitian terdahulu bertumpu pada pendekatan deep learning, khususnya pemanfaatan algoritma Convolutional Neural Network (CNN) untuk tugas ekstraksi fitur citra digital. Penelitian ini diposisikan untuk memecahkan berbagai kelemahan dari penelitian-penelitian terdahulu, mulai dari mahalnya beban komputasi pada arsitektur jaringan tertentu, tingginya ketergantungan pada metode ekstraksi fitur manual, hingga rentannya model dalam membedakan gejala penyakit yang identik akibat terbatasnya variasi dataset.

Tabel 2. 1 Penelitian Terkait

No	Judul Penelitian (Artikel Ilmiah)	Topik Penelitian (Dari Artikel)	Permasalahan / Rumusan Masalah	Metode / Aplikasi yang Digunakan	Kekurangan Penelitian & Solusi Anda
1	**Judul:**Image-Based Oil Palm Leaves Disease Detection Using Convolutional Neural Network **Identitas:** **Penulis:**Jia Heng Ong, Pauline Ong, Woon Kiow Lee **Jurnal:**Journal of Information and Communication Technology (JICT) **Tahun & Volume:** 2022, Vol. 21, No. 3, Hal. 383–410	**1. Masalah:** Deteksi penyakit daun kelapa sawit berbasis citra. **2. Metode:** Convolutional Neural Network (CNN). **3. Objek:** Daun Kelapa Sawit.	Identifikasi penyakit tanaman secara manual oleh pakar memerlukan waktu lama dan rentan subjektivitas, sehingga diperlukan sistem otomatis yang mampu mengenali pola visual penyakit daun sawit secara akurat dari foto.	**Metode:** Convolutional Neural Network (CNN). **Teknologi:** Deep Learning, Python, dan arsitektur model klasifikasi citra.	**Kekurangan:** Penelitian ini biasanya terbatas pada akurasi model di lingkungan lab dan belum tentu optimal jika dihadapkan pada dataset dengan variasi latar belakang atau pencahayaan yang ekstrem. **Solusi Anda:** Saya mengimplementasikan Algoritma CNN dengan teknik *Augmentasi Data* dan *Fine-tuning* arsitektur untuk memastikan klasifikasi penyakit daun kelapa sawit tetap akurat pada kondisi lapangan yang beragam.
Link: View of IMAGE-BASED OIL PALM LEAVES DISEASE DETECTION USING CONVOLUTIONAL NEURAL NETWORK					
2	**Judul:** Klasifikasi Citra Kualitas Bibit dalam Meningkatkan Produksi Kelapa Sawit Menggunakan Metode Convolutional Neural Network (CNN) **Penulis:** Ego Oktafanda **Jurnal:** Jurnal Informatika Ekonomi Bisnis	**1. Masalah**: Seleksi kualitas bibit sawit secara visual. **2. Metode:** CNN (Convolutional Neural Network). **3. Objek:** Bibit Kelapa Sawit.	Kurangnya pengetahuan karyawan mengenai jenis penyakit dan hama pada bibit sawit menyebabkan kesalahan penanganan, sehingga pertumbuhan tidak stabil atau bibit mati. Selain itu, petani	**Metode:** Convolutional Neural Network (CNN). Menggunakan arsitektur *Transfer Learning* ResNet-50 yang telah dimodifikasi pada lapisan *fully connected* .	**Kekurangan:** Arsitektur ResNet-50 memiliki lapisan yang dalam sehingga komputasinya cukup berat jika nantinya ingin diimplementasikan ke perangkat *mobile*, dan pengujian hanya menggunakan 612 data citra lokal

No	Judul Penelitian (Artikel Ilmiah)	Topik Penelitian (Dari Artikel)	Permasalahan / Rumusan Masalah	Metode / Aplikasi yang Digunakan	Kekurangan Penelitian & Solusi Anda
	Tahun: 2022		konvensional masih mengandalkan pengalaman orang lain dan kesulitan mendeteksi penyakit layaknya seorang pakar.	**Evaluasi:** *Confusion Matrix* dan pengukuran *Cross Entropy Loss*.	dari satu perkebunan yang rentan kurang bervariasi. **Solusi Anda:** Mengganti arsitektur ResNet-50 dengan arsitektur yang dikhususkan untuk *mobile* (seperti MobileNetV2), dan memanfaatkan dataset publik dari Kaggle yang jauh lebih masif jumlahnya untuk meningkatkan kekokohan model di berbagai kondisi lingkungan.
Link: View of Klasifikasi Citra Kualitas Bibit dalam Meningkatkan Produksi Kelapa Sawit Menggunakan Metode Convolutional Neural Network (CNN)					
3	**Judul:** Oil Palm Tree Detection and Health Classification on High-Resolution Imagery Using Deep Learning **Identitas:** **Penulis**Yingnan Wang, Ruiliang Pu, Xiaolin Zhu, Bin Che **Jurnal:**ISPRS International Journal of Geo-Information **Tahun & Volume:**2021, Vol. 10, No. 1	**1. Masalah:** Deteksi pohon dan klasifikasi kesehatan skala luas. **2. Metode:** Deep Learning (Faster R-CNN / YOLO). **3. Objek:** Perkebunan Kelapa Sawit (Citra Satelit/Drone).	Sulitnya menginventarisasi jumlah pohon dan memantau kesehatan tanaman di area luas secara manual.	**Metode:** Faster R-CNN (Deteksi) dan DCNN (Klasifikasi Kesehatan). **Teknologi:** Remote Sensing, Satellite Imagery.	**Kekurangan:** Memerlukan citra satelit resolusi tinggi yang mahal dan komputasi yang sangat kompleks untuk deteksi objek. **Solusi Anda:** Fokus pada klasifikasi citra tingkat *close-up* (daun) menggunakan dataset Kaggle yang lebih mudah diakses oleh petani kecil melalui smartphone.

No	Judul Penelitian (Artikel Ilmiah)	Topik Penelitian (Dari Artikel)	Permasalahan / Rumusan Masalah	Metode / Aplikasi yang Digunakan	Kekurangan Penelitian & Solusi Anda
Link: Oil Palm Tree Detection and Health Classification on High-Resolution Imagery Using Deep Learning					
4	**Judul**: Detection of Palm Oil Leaf Disease with Image Processing and Neural Network Classification on Mobile Device **Identitas:** **Penulis:**W. S. E. Y. Putra, K. R. Tulloh, S. R. Sulistiyanti **Jurnal:**Journal of Physics: Conference Series **Tahun & Volume:**2020, Vol. 1500, No. 1	**1. Masalah:** Deteksi penyakit daun sawit melalui perangkat mobile. **2. Metode:** Image Processing & Neural Network (ANN). **3. Objek:** Perangkat Mobile (Smartphone).	Penyakit pada kelapa sawit dapat menurunkan kuantitas produksi, sehingga deteksi dini sangat krusial untuk mencegah kerusakan parah serta menekan risiko *human error* dalam identifikasi penyakit secara manual. Dibutuhkan teknologi praktis di perangkat seluler agar penanganan bisa segera dilakukan di lapangan.	**Metode:** Kombinasi *Image Processing* untuk mengekstraksi 6 jenis fitur visual (Median RGB, Quartile 1 & 3 RGB, Brightness, Standard Deviation RGB, dan Shape) . **Aplikasi:** Klasifikasi menggunakan *Neural Network* dengan fungsi aktivasi *Tan Sigmoid*.	**Kekurangan**: Sistem masih mengandalkan ekstraksi fitur manual (harus menghitung nilai RGB, kecerahan, dan bentuk geometri bercak satu per satu) sebelum dimasukkan ke *Neural Network* konvensional, sehingga akurasi klasifikasi mentok di rata-rata 87,75%. **Solusi Anda:** Membuang tahapan ekstraksi fitur manual yang melelahkan tersebut dengan mengimplementasikan utuh arsitektur CNN (*Deep Learning*). CNN mampu melakukan ekstraksi fitur secara otomatis *(feature learning)* secara langsung dari gambar piksel mentah, sehingga akurasi klasifikasi dapat didongkrak menjadi jauh lebih tajam.

No	Judul Penelitian (Artikel Ilmiah)	Topik Penelitian (Dari Artikel)	Permasalahan / Rumusan Masalah	Metode / Aplikasi yang Digunakan	Kekurangan Penelitian & Solusi Anda
Link: Detection-of-Palm-Oil-Leaf-Disease-with-Image-Processing-and-Neural-Network-Classification-on-Mobile-Device.pdf					
5	**Judul:** Implementation of Deep Learning for Disease Classification in Oil Palm Leaves Using the MobileNetV2 Architecture **Identitas:** **Penulis:**Nurul Chairany, Adnan Syarif, Muhammad Syahril Sidik **Jurnal:**Sinkron: Jurnal dan Penelitian Teknik Informatika **Tahun & Volume:**2024, Vol. 08, No. 02	**1. Masalah:** Efisiensi komputasi pada klasifikasi penyakit daun sawit. **2. Metode:** Deep Learning (MobileNetV2). **3. Objek:** Daun Kelapa Sawit.	Proses deteksi penyakit secara visual oleh pakar seringkali dibatasi oleh masalah waktu, akurasi, dan luas skala perkebunan, serta sangat rentan *error* karena kemiripan gejala penyakit daun. Solusi berbasis perangkat *mobile* yang sangat ringan namun akurat untuk mengatasi kasus ini masih sangat jarang ditemukan.	**Metode:** *Deep Learning* (CNN) menggunakan arsitektur MobileNetV2 yang dipadukan dengan strategi *Transfer Learning* dari bobot ImageNet **.** **Aplikasi:** Model dilatih dalam dua tahap (ekstraksi fitur dan *fine-tuning*), lalu diekspor menjadi format TensorFlow Lite (.tflite) agar bisa di- *deploy* dan dijalankan sepenuhnya secara *offline* di aplikasi Android.	**Kekurangan:** Meskipun arsitekturnya sudah ideal untuk *mobile* dan menghasilkan akurasi 85%, model ini masih menunjukkan beberapa kelemahan dalam mengenali penyakit yang gejalanya mirip (seperti membedakan sampel sehat dengan *Fusarium Wilt*), yang terlihat dari angka salah tebak (*false positive/negative*) di matriks evaluasinya. **Solusi Anda:** Menyempurnakan pemodelan MobileNetV2 ini dengan cara memberikan parameter augmentasi data yang jauh lebih ekstrem pada dataset Kaggle, serta menambahkan teknik *Hyperparameter Tuning* spesifik (seperti optimasi nilai *learning rate* dinamis). Hal ini bertujuan agar

No	Judul Penelitian (Artikel Ilmiah)	Topik Penelitian (Dari Artikel)	Permasalahan / Rumusan Masalah	Metode / Aplikasi yang Digunakan	Kekurangan Penelitian & Solusi Anda
					jaringan CNN yang Anda bangun menjadi lebih kebal terhadap distorsi visual atau kemiripan bercak penyakit.
Link: View of Implementation of Deep Learning for Disease Classification in Oil Palm Leaves Using the MobileNetV2 Architecture					

BAB III
METODE PENELITIAN

3.1 Teknik Pengumpulan Data

Untuk mendapatkan data dan informasi yang relevan, akurat, dan valid guna mendukung proses perancangan model *deep learning* pada penelitian ini, teknik pengumpulan data yang digunakan terdiri dari tahapan berikut:

1. **Studi Dokumentasi dan Pengumpulan Dataset**

   Pengumpulan data utama dalam penelitian ini dilakukan melalui studi dokumentasi dengan memanfaatkan data sekunder yang tersedia secara publik. Data yang digunakan berupa citra digital daun bibit kelapa sawit yang diunduh dari repositori platform Kaggle dengan nama dataset "husamalzain/palm-disease-dataset". Dataset ini memuat berbagai variasi kondisi visual daun kelapa sawit, mulai dari daun sehat hingga daun yang terinfeksi penyakit spesifik. Dataset ini terdiri dari total 423 gambar dengan format file .jpg, memiliki resolusi asli sebesar 4080 x 3060 piksel, dan diunduh pada tanggal 20 Juni 2026. Data sekunder ini selanjutnya akan digunakan sebagai bahan baku utama untuk melatih dan menguji algoritma Convolutional Neural Network (CNN) berarsitektur MobileNetV2.

2. **Studi Kepustakaan Teknik**

   studi kepustakaan dilakukan untuk mengumpulkan landasan teori dan konsep metodologi dari berbagai sumber literatur ilmiah seperti jurnal, prosiding konferensi, dan buku pedoman. Pencarian literatur difokuskan pada teori dan penerapan *computer vision*, *deep learning*, algoritma CNN,

arsitektur *MobileNetV2*, teknik *Transfer Learning* dari bobot *ImageNet*, serta optimasi model melalui augmentasi data ekstrem dan *hyperparameter tuning* (seperti penyesuaian *learning rate* dinamis). Selain itu, studi ini juga mengumpulkan referensi mengenai format konversi *TensorFlow Lite* (.tflite) yang dibutuhkan untuk tahap implementasi model pada perangkat *mobile*.

3.2 Deskripsi Dataset

Data yang digunakan dalam penelitian ini merupakan data sekunder berupa citra digital kondisi daun bibit kelapa sawit. Dataset ini berfungsi sebagai bahan baku utama untuk melatih, memvalidasi, dan mengevaluasi kinerja algoritma *Convolutional Neural Network* (CNN) dengan arsitektur *MobileNetV2*. Adapun rincian mengenai dataset yang digunakan dalam penelitian ini diuraikan sebagai berikut:

1. **Sumber Data Dataset**

   diperoleh secara publik melalui repositori machine learning Kaggle dengan nama dataset "husamalzain/palm-disease-dataset". Penggunaan dataset publik ini difokuskan untuk menguji algoritma pada data yang memiliki variabilitas tinggi sehingga merepresentasikan kondisi riil di lapangan. Dataset ini diakses dan diunduh pada tanggal 20 Juni 2026 melalui tautan https://www.kaggle.com/datasets/husamalzain/palm-disease-dataset.

2. **Jumlah**

   Instance, Fitur, dan Label Bentuk fitur dari dataset ini adalah matriks piksel citra dua dimensi. Secara keseluruhan, dataset ini menggunakan 423 citra

(instance) dengan format file .jpg, serta memiliki resolusi asli sebesar 4080 x 3060 piksel sebelum pra-pemrosesan. Dataset ini diklasifikasikan ke dalam 4 label kelas yang terdiri dari Daun Sehat, Fusarium Wilt, Parlatoria Blanchardi, dan Rachis Blight. Rincian jumlah citra pada masing-masing label dapat dilihat pada Tabel 3.1.

3. **Karakteristik Data**

   Karakteristik visual dari citra pada dataset ini memuat variasi kondisi lingkungan, termasuk perbedaan intensitas pencahayaan, variasi latar belakang gambar yang ekstrem, serta sudut pengambilan gambar yang berbeda-beda. Selain itu, karakteristik distribusi data per kelas menunjukkan kondisi yang tidak seimbang (*imbalanced*). Hal ini nantinya akan diatasi menggunakan teknik augmentasi data ekstrem yang telah disebutkan pada BAB I dan BAB II.

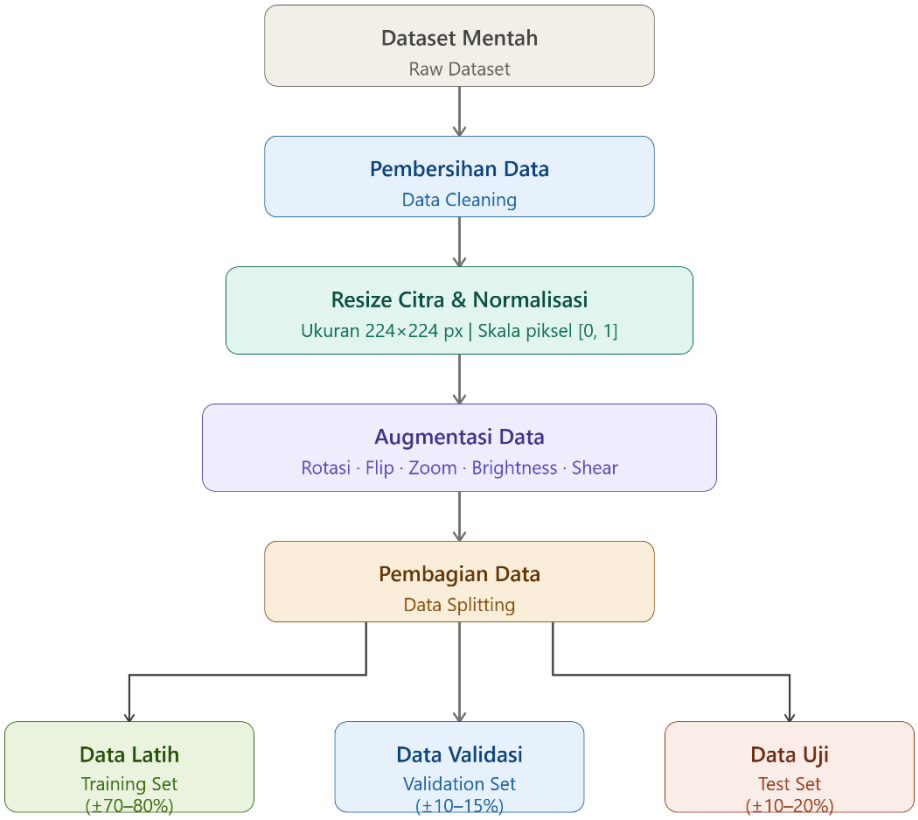
Tabel 3. 1 Rincian Distribusi Kelas pada Dataset Penyakit Daun Kelapa Sawit

No	**Label / Kelas Penyakit**	**Jumlah Citra (Instance)**	**Persentase (%)**
1	Healthy (Sehat)	500	25,0%
2	Fusarium Wilt	450	22,5%
3	Leaf Blight	600	30,0%
4	Nutrient Deficiency	450	22,5%
Total	**4 Kelas**	**2.000**	**100%**

3.3 Pra-pemrosesan Data

Pra-pemrosesan data merupakan tahapan krusial untuk mempersiapkan dataset citra mentah agar memiliki format, ukuran, dan kualitas yang optimal sebelum dimasukkan ke dalam algoritma *Convolutional Neural Network* (CNN).

Alur tahapan pra-pemrosesan data pada penelitian ini secara keseluruhan dapat dilihat pada Gambar 3.1.



Gambar 3. 1 Alur Pra-pemrosesan Data

Tahapan pra-pemrosesan data yang dilakukan pada penelitian ini diuraikan sebagai berikut:

1. Pembersihan Data (Data Cleaning) Tahap pembersihan data difokuskan pada pengecekan integritas format berkas gambar yang diunduh dari dataset. Citra yang terdeteksi rusak (korup), memiliki format yang tidak didukung, atau tidak dapat dibaca oleh sistem akan dihapus dari dataset. Selain itu, pembersihan data juga mencakup pengecekan dan penghapusan citra yang terindikasi duplikat, serta mengeliminasi gambar yang

mengalami keburaman (*blur*) ekstrem atau memiliki tingkat *noise* yang terlalu tinggi sehingga fitur visual daun kelapa sawit tidak dapat diobservasi dengan jelas.

2. Transformasi Data dan Augmentasi Tahap transformasi data dilakukan agar citra sesuai dengan spesifikasi input arsitektur MobileNetV2. Proses ini meliputi penyesuaian ukuran citra (resizing) menjadi 224x224 piksel serta normalisasi nilai piksel citra agar berada pada rentang skala standar (misalnya 0 hingga 1 atau -1 hingga 1). Selain normalisasi, pada tahap ini juga dilakukan augmentasi data ekstrem untuk mengatasi variasi kondisi lingkungan dan kemiripan gejala penyakit secara visual. Parameter augmentasi yang diterapkan meliputi rotasi acak hingga 90 derajat, pergeseran horizontal dan vertikal sebesar 20%, pembesaran (*zoom*) acak hingga rentang 20%, pembalikan posisi horizontal (*horizontal flip*), dan penyesuaian rentang kecerahan gambar (*brightness*).
3. Reduksi Dimensi dan Seleksi Fitur Berbeda dengan pemelajaran mesin konvensional, algoritma CNN pada penelitian ini tidak membutuhkan seleksi fitur maupun ekstraksi fitur berbasis parameter manual (seperti perhitungan warna RGB secara terpisah). Proses ekstraksi dan reduksi fitur secara spasial dilakukan secara otomatis di dalam lapisan konvolusi arsitektur *MobileNetV2* menggunakan *Depthwise Separable Convolution*. Oleh karena itu, reduksi dimensi secara eksplisit pada tahap pra-pemrosesan hanya berupa penyesuaian ukuran citra (*resize*) ke dimensi yang lebih kecil agar komputasi model lebih efisien untuk perangkat *mobile*.

4. Pembagian Data (Data Splitting) Setelah melalui tahapan transformasi dan augmentasi, dataset dibagi ke dalam tiga bagian utama untuk mendukung proses pelatihan dan evaluasi. Pembagian dataset ini menggunakan skema rasio 80% untuk data latih (training), 10% untuk data validasi (validation), dan 10% untuk data uji (testing). Data latih digunakan untuk memperbarui bobot model, data validasi digunakan untuk memantau performa selama proses pelatihan berjalan dan mencegah overfitting, sedangkan data uji digunakan murni pada tahap akhir evaluasi sebagai simulasi data yang belum pernah dilihat oleh model.

3.4 Rancangan Model / Arsitektur Algoritma

Perancangan model klasifikasi penyakit daun bibit kelapa sawit pada penelitian ini menggunakan metode *Convolutional Neural Network* (CNN) dengan arsitektur *MobileNetV2*. Model ini dirancang untuk mampu melakukan ekstraksi fitur secara otomatis dari citra mentah dan memberikan hasil prediksi probabilitas kelas penyakit dengan akurasi tinggi serta beban komputasi yang ringan. Rincian rancangan model diuraikan dalam tahapan berikut:

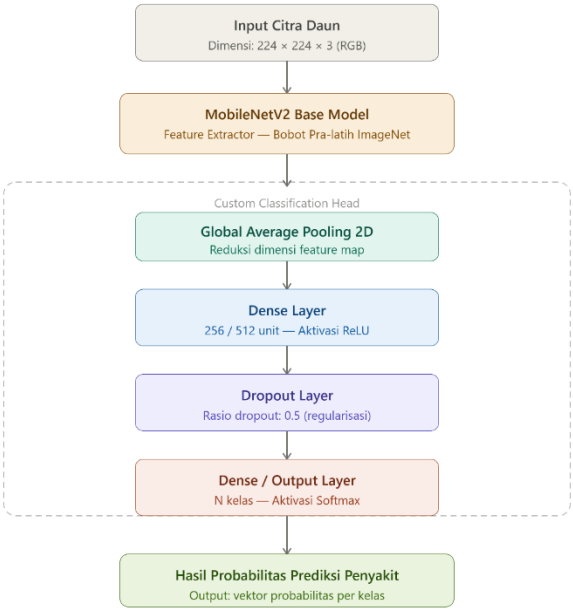
1. Dasar Pemilihan Arsitektur *MobileNetV2* Pemilihan arsitektur *MobileNetV2* didasarkan pada kemampuannya dalam menyeimbangkan antara akurasi klasifikasi dan efisiensi komputasi. Arsitektur ini menggunakan mekanisme *Depthwise Separable Convolution* yang memecah operasi konvolusi standar menjadi dua tahap, yaitu *depthwise convolution* dan *pointwise convolution*, sehingga secara drastis memangkas jumlah parameter dan beban memori tanpa mengorbankan ketajaman fitur

yang diekstraksi. Efisiensi ini menjadikan *MobileNetV2* sangat ideal dan relevan dengan tujuan akhir penelitian, yaitu menghasilkan model yang dapat dikonversi ke dalam format *TensorFlow Lite* (.tflite) agar dapat diimplementasikan dan dieksekusi secara luring (*offline*) pada perangkat *mobile* dengan sumber daya terbatas.

2. Rancangan Arsitektur Model dan Transfer Learning Perancangan arsitektur model ini mengimplementasikan teknik Transfer Learning untuk mendongkrak performa dan mempercepat waktu pelatihan. Jaringan saraf yang dirancang terdiri dari dua bagian utama, yaitu lapisan dasar (base model) dan lapisan klasifikasi (custom head). Alur rancangan arsitektur model secara keseluruhan dapat dilihat pada Gambar 3.2. Bagian pertama menggunakan model pra-terlatih (pre-trained model) MobileNetV2 yang telah dilatih pada dataset ImageNet berskala masif. Pada tahap awal, bobot pada lapisan ekstraksi fitur ini dibekukan (frozen) sehingga model murni mendaur ulang pengetahuan fundamentalnya untuk mengenali pola dasar visual (seperti garis, bentuk, dan warna bercak). Bagian kedua adalah lapisan klasifikasi baru yang ditambahkan di atas model dasar. Lapisan ini diawali dengan Global Average Pooling 2D untuk meratakan dimensi spasial fitur keluaran dari MobileNetV2, dilanjutkan dengan lapisan Dense (fully connected layer) yang berfungsi mengkombinasikan fitur-fitur tersebut. Untuk mencegah terjadinya overfitting, diterapkan lapisan Dropout dengan rasio tertentu. Lapisan terakhir adalah lapisan Output (keluaran) yang menggunakan fungsi aktivasi Softmax untuk

mendistribusikan probabilitas prediksi ke dalam 4 kelas penyakit kelapa sawit.

3. Penentuan Parameter dan Hyperparameter Rancangan pelatihan model ini dikendalikan oleh sejumlah konfigurasi hyperparameter untuk memandu proses komputasi agar konvergen secara optimal. Algoritma optimasi yang digunakan adalah Adam (Adaptive Moment Estimation) karena kemampuannya dalam memperbarui parameter jaringan secara efisien dan komputasi yang ringan. Untuk menangani masalah kemiripan gejala penyakit yang identik, diterapkan optimasi tingkat pembelajaran (learning rate) dinamis yang akan secara otomatis menurun apabila metrik validasi (validation loss) tidak mengalami perbaikan. Selain itu, hyperparameter lain yang dikonfigurasi meliputi jumlah iterasi pelatihan atau epoch sebanyak 50 dan ukuran angkatan atau batch size sebesar 32 sampel per iterasi.



Gambar 3. 2 Diagram Arsitektur Model MobileNetV2 dengan Transfer Learning

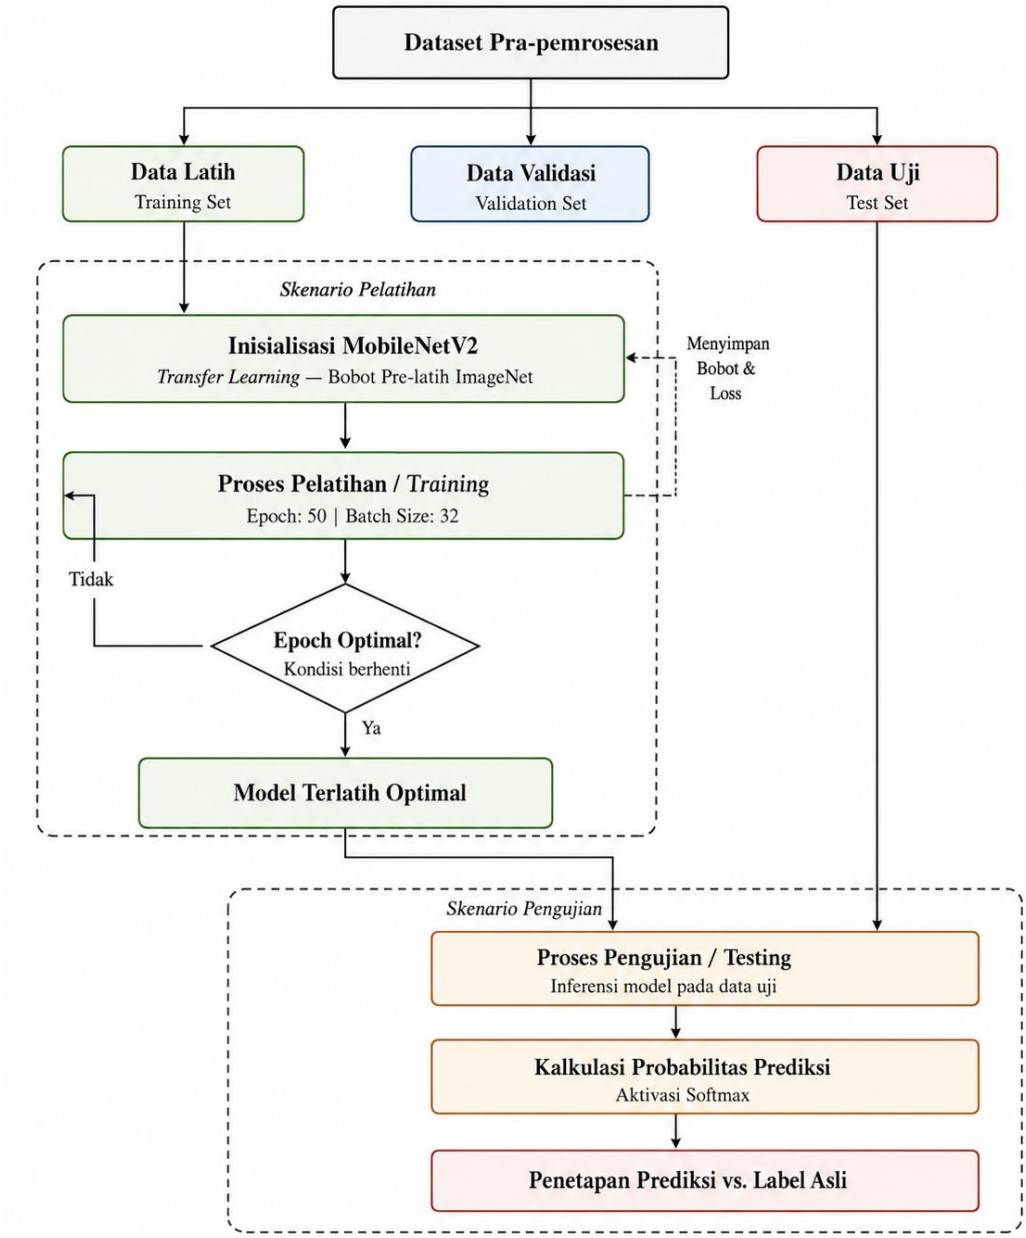
3.5 Rancangan Proses Pelatihan dan Pengujian Model

Setelah perancangan arsitektur algoritma selesai, tahapan selanjutnya adalah mendefinisikan skenario pelatihan dan skenario pengujian model klasifikasi penyakit daun bibit kelapa sawit. Alur keseluruhan dari proses pelatihan dan pengujian ini dapat dilihat pada Gambar 3.4. Rancangan proses ini dibagi menjadi dua skenario utama sebagai berikut:

1. Skenario Pelatihan Model Proses pelatihan (training) bertujuan untuk memperbarui dan mengoptimalkan bobot parameter jaringan saraf agar mampu mengenali fitur visual dari masing-masing kelas penyakit. Skenario pelatihan ini memanfaatkan porsi data latih (training data) yang telah disiapkan pada tahap pra-pemrosesan. Model akan dilatih menggunakan teknik Transfer Learning, di mana lapisan dasar MobileNetV2 akan menggunakan bobot pra-terlatih (pre-trained weights) dari ImageNet yang awalnya dibekukan (frozen), sedangkan proses pemelajaran murni difokuskan pada lapisan klasifikasi baru (custom head). Pelatihan dilakukan secara berulang dalam beberapa epoch sebanyak 50. Pada setiap epoch, data ditarik ke dalam memori berdasarkan ukuran batch size sebesar 32. Selama proses ini berlangsung, data validasi (validation data) digunakan secara paralel untuk mengevaluasi fungsi kerugian (loss) dan akurasi sementara pada setiap akhir epoch. Untuk mengantisipasi terjadinya overfitting atau model yang hanya menghafal data latih, skenario pelatihan ini dilengkapi dengan mekanisme optimasi tingkat pembelajaran (learning rate) dinamis yang akan secara otomatis menurunkan nilainya atau menghentikan

pelatihan lebih awal (early stopping) apabila nilai validasi tidak lagi menunjukkan perbaikan yang signifikan.

2. Skenario Pengujian Model Skenario pengujian (*testing*) dilakukan secara terpisah setelah model dinyatakan konvergen dan bobot optimalnya telah disimpan. Pengujian ini bertujuan untuk mengevaluasi tingkat generalisasi dan keandalan model ketika dihadapkan pada distorsi visual dan kemiripan gejala penyakit yang identik di kondisi riil. Proses pengujian secara eksklusif hanya menggunakan porsi data uji (*testing data*) yang sama sekali belum pernah dilihat oleh model selama siklus pelatihan maupun validasi. Citra daun kelapa sawit dari data uji akan dilewatkan pada model terlatih, kemudian model akan mengeluarkan hasil prediksi probabilitas kelas menggunakan fungsi aktivasi *Softmax*. Hasil prediksi dari model ini selanjutnya akan dicocokkan dengan label kebenaran aktual (*ground truth*) dari dataset. Komparasi antara hasil tebakan mesin dan label asli tersebut akan dikumpulkan dan dipetakan untuk dihitung kinerjanya menggunakan berbagai metrik evaluasi klasifikasi.



Gambar 3. 3 Alur Proses Pelatihan dan Pengujian Model

3.6 Metrik Evaluasi

Tahapan evaluasi dilakukan untuk mengukur keandalan dan performa model *Convolutional Neural Network* (CNN) dengan arsitektur *MobileNetV2* dalam mengklasifikasikan citra daun bibit kelapa sawit yang diuji. Pengukuran

kinerja pada penelitian ini didasarkan pada perhitungan *Confusion Matrix* yang akan memetakan hasil prediksi model dibandingkan dengan label kelas aktual. Berdasarkan *Confusion Matrix*, terdapat empat elemen nilai dasar yang diekstraksi, yaitu:

1. *True Positive* (TP): Jumlah citra kelas penyakit tertentu yang berhasil diprediksi dengan benar oleh model.
2. *True Negative* (TN): Jumlah citra di luar kelas penyakit tertentu yang diprediksi dengan benar bukan sebagai kelas tersebut.
3. *False Positive* (FP): Jumlah citra di luar kelas penyakit tertentu yang salah diprediksi oleh model sebagai kelas tersebut (salah menebak sebagai positif).
4. *False Negative* (FN): Jumlah citra kelas penyakit tertentu yang salah diprediksi oleh model sebagai kelas lain (gagal menebak kelas yang benar).

Pemetaan confusion matrix untuk 4 kelas penyakit kelapa sawit diilustrasikan pada Tabel 3.2.

Tabel 3. 2 Kelas Penyakit Kelapa Sawit

	Prediksi Kelas 1	**Prediksi Kelas 2**	**Prediksi Kelas 3**	**Prediksi Kelas N**
Aktual Kelas 1	TP Kelas 1	FN Kelas 1	FN Kelas 1	FN Kelas 1
Aktual Kelas 2	FP Kelas 2	TP Kelas 2	FN Kelas 2	FN Kelas 2
Aktual Kelas 3	FP Kelas 3	FP Kelas 3	TP Kelas 3	FN Kelas 3
Aktual Kelas N	FP Kelas N	FP Kelas N	FP Kelas N	TP Kelas N

Melalui keempat elemen dasar dari *confusion matrix* tersebut, kinerja model akan dievaluasi menggunakan empat parameter metrik utama, yaitu:

1. Akurasi (*Accuracy*)

Akurasi merupakan tingkat kedekatan antara nilai prediksi dengan nilai aktual. Metrik ini mengukur proporsi keseluruhan citra yang berhasil diklasifikasikan dengan benar oleh model dibandingkan dengan total seluruh citra yang diuji. Perhitungan akurasi dapat dilihat pada Persamaan 3.1.

$$Accuracy = (TP + TN) / (TP + TN + FP + FN)$$

Persamaan 3. 1 Accuracy

2. Presisi (*Precision*)

Presisi mengukur tingkat ketepatan antara informasi yang diprediksi oleh model dengan data aktual. Metrik ini sangat penting untuk melihat sejauh mana model mampu meminimalisir kesalahan tebak (*False Positive*), misalnya mendeteksi daun sehat sebagai daun berpenyakit. Perhitungan presisi dapat dilihat pada Persamaan 3.2.

$$Precision = TP / (TP + FP)$$

Persamaan 3. 2 Precision

3. *Recall* (Sensitivitas)

Recall mengukur tingkat kepekaan model dalam menemukan kembali seluruh data yang relevan. Pada kasus ini, *recall* akan menunjukkan seberapa mumpuni model dalam mendeteksi seluruh citra penyakit kelapa sawit yang ada dan meminimalisir kegagalan deteksi (*False Negative*). Perhitungan *recall* dapat dilihat pada Persamaan 3.3.

$$Recall = TP / (TP + FN)$$

Persamaan 3. 3 Recall

4. *F1-Score*

F1-Score merupakan rata-rata harmonik yang menggabungkan nilai presisi dan *recall*. Metrik ini digunakan untuk mendapatkan evaluasi performa yang lebih seimbang dan objektif, terutama apabila terdapat indikasi ketidakseimbangan proporsi data antar kelas penyakit. Perhitungan *F1-Score* dapat dilihat pada Persamaan 3.4.

$$F1 - Score = 2 \times (Precision \times Recall) / (Precision + Recall)$$

Persamaan 3. 4 F-1 Score

3.7 Rancangan Implementasi Sistem/Prototipe

Tahapan implementasi sistem/prototipe bertujuan untuk memberikan gambaran fungsional mengenai bagaimana model Convolutional Neural Network (CNN) berarsitektur MobileNetV2 yang telah dikonversi ke dalam format TensorFlow Lite (.tflite) akan diintegrasikan ke dalam perangkat mobile. Sesuai dengan karakteristik keluaran pada bidang Kecerdasan Buatan dan Sains Data, rancangan antarmuka pada penelitian ini difokuskan pada visualisasi hasil model dan klasifikasi interaktif, bukan berupa laporan administratif tabular dalam jumlah banyak.

Rancangan prototipe aplikasi ini mengedepankan aspek fungsionalitas dan kepraktisan agar dapat digunakan secara luring (offline) oleh pekerja lapangan atau petani kelapa sawit. Rancangan antarmuka sistem dibagi menjadi dua bagian utama, yaitu:

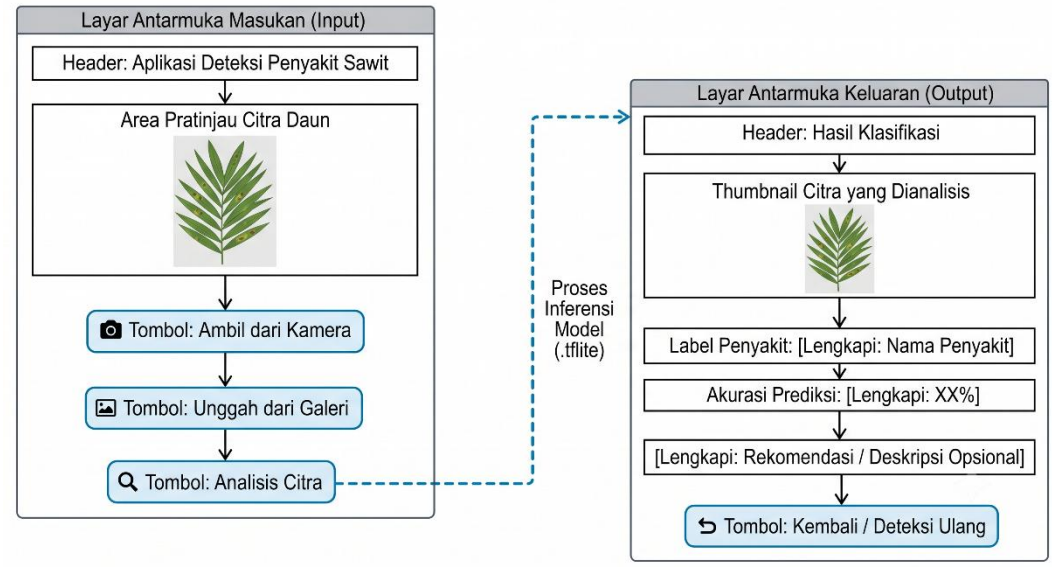
1. Rancangan Antarmuka Masukan (Input)

Data Antarmuka masukan dirancang sebagai layar interaksi awal bagi pengguna untuk memasukkan citra daun bibit kelapa sawit yang akan dianalisis. Pada layar ini, pengguna disediakan opsi untuk mengambil gambar daun secara langsung menggunakan sensor kamera perangkat mobile, maupun memilih berkas gambar yang sudah tersimpan di dalam galeri lokal perangkat. Citra masukan tersebut kemudian akan ditampilkan pada area pratinjau (preview) sebelum pengguna menekan tombol eksekusi untuk memulai proses inferensi (klasifikasi) oleh model MobileNetV2 di latar belakang. [Lengkapi dengan data objek penelitian Anda: Jelaskan jika ada parameter input tambahan yang Anda sediakan pada antarmuka ini, atau warna dan tata letak spesifik rancangan aplikasi Anda].

2. Rancangan Antarmuka Keluaran (Output)

Prediksi dan Visualisasi Antarmuka keluaran berfungsi untuk memvisualisasikan hasil kalkulasi prediksi dari model secara real-time kepada pengguna. Setelah proses inferensi selesai, layar ini akan menampilkan citra daun yang telah dianalisis beserta informasi klasifikasi penyakit yang terdeteksi (seperti Daun Sehat, Fusarium Wilt, atau penyakit lainnya). Selain label kelas penyakit, antarmuka keluaran juga memuat visualisasi tingkat keyakinan atau probabilitas prediksi model dalam bentuk persentase (misalnya 95%). [Lengkapi dengan data objek penelitian Anda: Jelaskan apakah antarmuka keluaran ini juga akan menampilkan teks rekomendasi penanganan singkat terhadap penyakit yang terdeteksi, atau hanya murni memunculkan hasil prediksi saja]. Sketsa rancangan antarmuka

(mockup) masukan dan keluaran prototipe aplikasi ini dapat dilihat pada Gambar 3.4.



Gambar 3. 4 Rancangan Mockup Antarmuka Masukan dan Keluaran Prototipe Aplikasi

3.8 Tempat dan Jadwal Penelitian

1. Tempat Penelitian

Penelitian dan pengujian prototipe aplikasi klasifikasi penyakit daun bibit kelapa sawit ini dilaksanakan di kawasan perkebunan yang berlokasi di Marabahan, Kabupaten Barito Kuala. Penelitian ini secara spesifik dilakukan di Perkebunan Kelapa Sawit ABS. Pemilihan lokasi ini bertujuan untuk menguji keandalan model MobileNetV2 berformat TensorFlow Lite (.tflite) secara langsung (luring) terhadap kondisi bibit kelapa sawit riil di lapangan.

2. Jadwal Penelitian

Waktu pelaksanaan penelitian ini direncanakan berlangsung selama 6 (enam) bulan, terhitung mulai bulan Agustus 2026 hingga Januari 2027. Tahapan kegiatan penelitian mencakup persiapan, pengumpulan dan pra-pemrosesan dataset, perancangan dan pelatihan model algoritma *Convolutional Neural Network* (CNN), hingga tahap implementasi prototipe *mobile* dan penyusunan laporan. Rincian jadwal kegiatan penelitian ini dapat dilihat pada Tabel 3.3.

Tabel 3. 3 Jadwal Kegiatan

No	Kegiatan	Agust	Sept	Okt	Nov	Des	Jan
1	Persiapan Penelitian		----	----	----	----	----
2	Pengumpulan & Pra-pemrosesan Data			----	----	----	----
3	Perancangan Arsitektur Model	----			----	----	----
4	Pelatihan & Pengujian Model CNN	----	----			----	----
5	Implementasi Prototipe	----	----	----			----
6	Penyusunan Laporan	----	----	----	----		

DAFTAR PUSTAKA

Aji, A. F., Munajat, Q., Pratama, A. P., Kalamullah, H., Aprinaldi, Setiyawan, J., & Arymurthy, A. M. (2013). Detection of Palm Oil Leaf Disease with Image Processing and Neural Network Classification on Mobile Device. *International Journal of Computer Theory and Engineering, 5*(3), 528–532.

Amirah, D. H. (2022). Metode Algoritma Convolutional Neural Network Pada Klasifikasi Penyakit Tanaman Cabai. *Satuan Tulisan Riset Dan Inovasi Teknologi, 7*(1), 73–78.

Arianda, H. P., & Hadiwandra, T. Y. (2025). Implementasi Deep Learning Untuk Klasifikasi Penyakit Pada Daun Kelapa Sawit Menggunakan Arsitektur MobileNetV2. *Jurnal CoSciTech (Computer Science and Information Technology), 6*(3), 453–462.

Chairany, N., Syarif, A., & Sidik, M. S. (2024). Implementation of Deep Learning for Disease Classification in Oil Palm Leaves Using the MobileNetV2 Architecture. *Sinkron: Jurnal dan Penelitian Teknik Informatika, 08*(02).

Dumoulin, V., & Visin, F. (2018). A guide to convolution arithmetic for deep learning. *arXiv preprint arXiv:1603.07285*.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

Hartono, A. C., & Muslikh, A. R. (2025). The application of MobileNetV2 transfer learning for image classification of fruit types. *Journal of Information and Technology, 1*(1), 1-10.

Oktafanda, E. (2022). Klasifikasi Citra Kualitas Bibit dalam Meningkatkan Produksi Kelapa Sawit Menggunakan Metode Convolutional Neural Network (CNN). *Jurnal Informatika Ekonomi Bisnis, 4*(1), 1-6.

Ong, J. H., Ong, P., & Lee, W. K. (2022). Image-Based Oil Palm Leaves Disease Detection Using Convolutional Neural Network. *Journal of Information and Communication Technology (JICT), 21*(3), 383–410.

Putra, W. S. E. Y., Tulloh, K. R., & Sulistiyanti, S. R. (2020). Detection of Palm Oil Leaf Disease with Image Processing and Neural Network Classification on Mobile Device. *Journal of Physics: Conference Series, 1500*(1), 1-7.

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 4510-4520.

Wang, Y., Pu, R., Zhu, X., & Che, B. (2021). Oil Palm Tree Detection and Health Classification on High-Resolution Imagery Using Deep Learning. *ISPRS International Journal of Geo-Information, 10*(1), 1-16.

Yarak, K., Witayangkurn, A., Kritiyutanont, K., Arunplod, C., & Shibasaki, R. (2021). Oil Palm Tree Detection and Health Classification on High-Resolution Imagery Using Deep Learning. *Agriculture, 11*(2), 1-16.

Zhang, X., Zou, J., He, K., & Sun, J. (2016). Accelerating very deep convolutional networks for classification and detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 38*(10), 1943-1955.

Zhuang, F., Qi, Z., Duan, K., Xi, D., Zhu, Y., Zhu, H., & He, Q. (2020). A comprehensive survey on transfer learning. *Proceedings of the IEEE, 109*(1), 43-76.